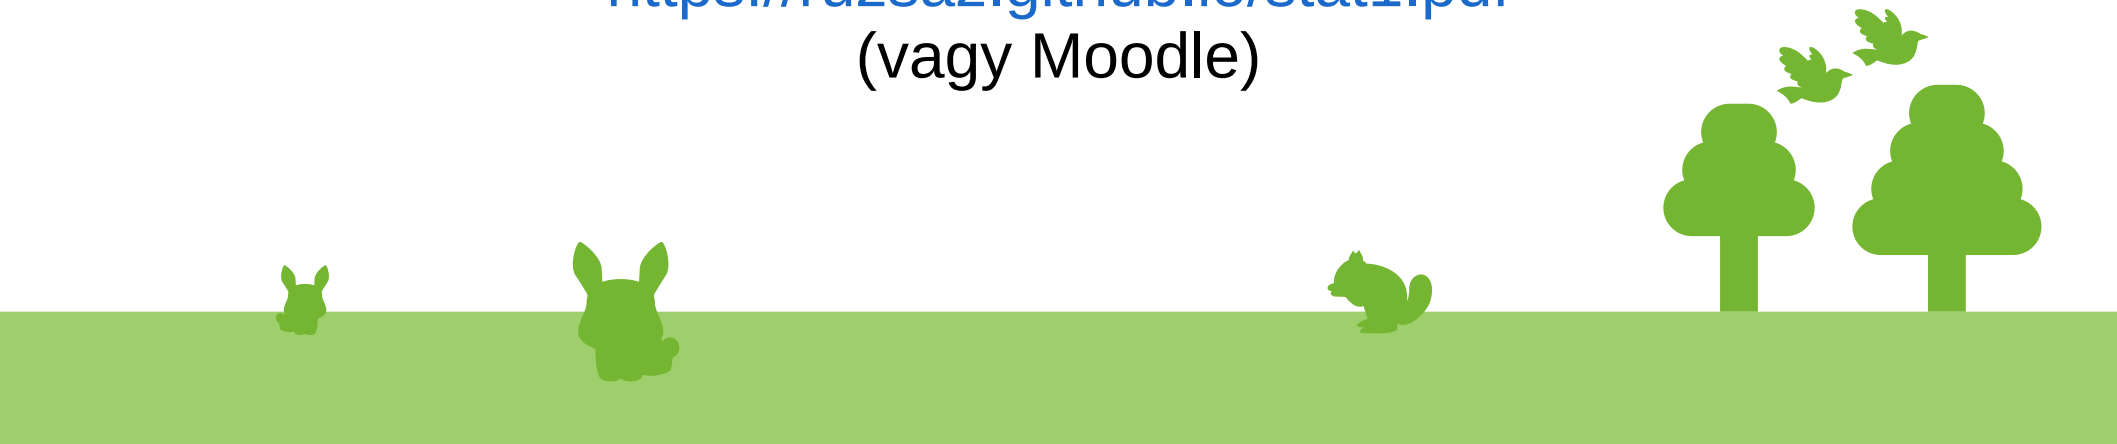
Kvantitatív kutatási módszertanok 1

Ruzsa Zoltán
ruzsa.zoltan@emk.semmelweis.hu

https://ruzsaz.github.io/stat1.pdf
(vagy Moodle)



VÁLASZTÁSI FÖLDRAJZ

A magyarok fele olyan településen él, ahol a jövedelem nem éri el az országos átlagot

VÁLASZTÁSI FÖLDRAJZ GAZDASÁG 2025. január 24. – 04:58



telex
Kövess minket Facebookon is!
Követem!

Legfontosabb



KÜLFÖLD

Mi várható a Kennedy-aktáktól, amikből Trump szerint minden kiderül?

Tematika

- Leíró statisztika (átlag, medián, módusz, szórás...)
- Paraméterbecslés (mennyi?)
- Hipotézisvizsgálat (igaz vagy nem?)
- Regressziószámítás, modellezés (hogy befolyásol?)
- Kazualitás (ok-okozat) bizonyítása



Eszköz (R, python)

1) R saját gépen

2) Python saját gépen

3) Google colab: https://colab.research.google.com/

4) AI



Leíró statisztika

- Mit jelent a „statisztika” szó?
- Mi a leíró statisztika?
- Adjunk való életből származó példákat!

Leíró statisztika

- Mit jelent a „statisztika” szó?
- Mi a leíró statisztika?
- Adjunk való életből származó példákat!

latin "statisticus" = államhoz tartozó



Leíró statisztika

- Mit jelent a „statisztika” szó?
- Mi a leíró statisztika?
- Adjunk való életből származó példákat!

latin "statisticus" = államhoz tartozó

adathalmaz összefoglalása és bemutatása, **anélkül, hogy következtetéseket vonnánk le**



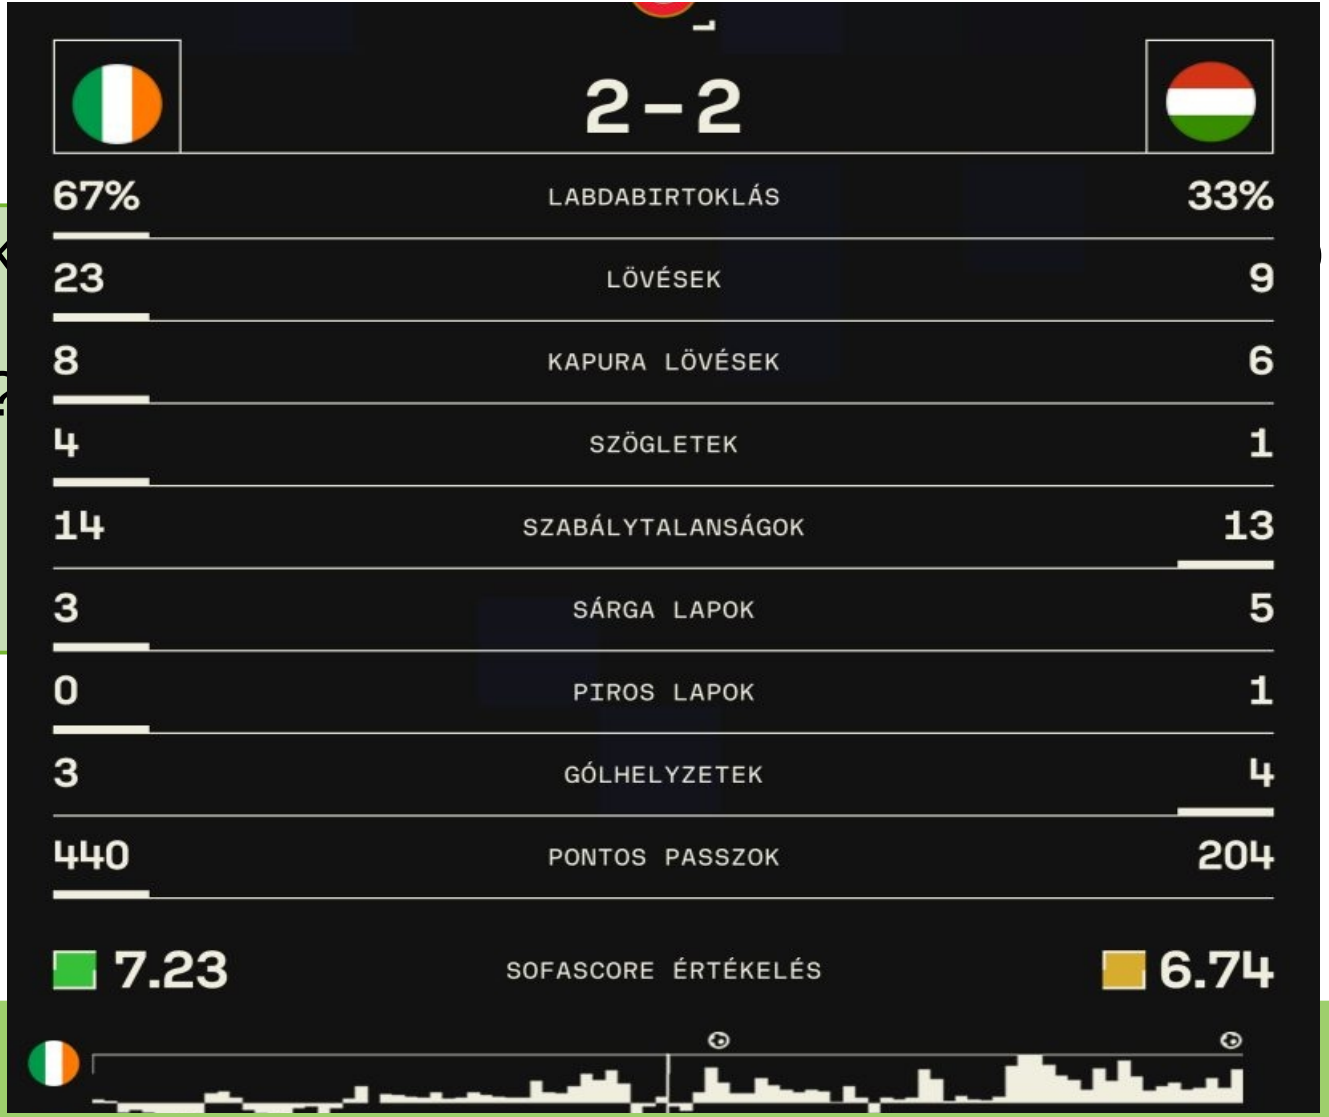
Leíró statisztika

- Mit jelent
- Mi a leíró
- Adjunk va
  származó



- Mit jelent a „statisztik
- Mi a leíró statisztika?
- Adjunk való életből származó példákat!





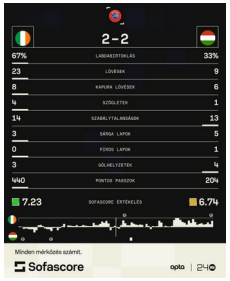
Leíró statisztika

- Mit jelent a „statisztika” szó?
- Mi a leíró statisztika?
- Adjunk való életből származó példákat!

latin "statisticus" = államhoz tartozó

adathalmaz összefoglalása és bemutatása, anélkül, hogy következtetéseket vonnánk le





Leíró statisztika

- 1. momentum (várható érték)

- 2. momentum (szórásnégyzet = variancia)

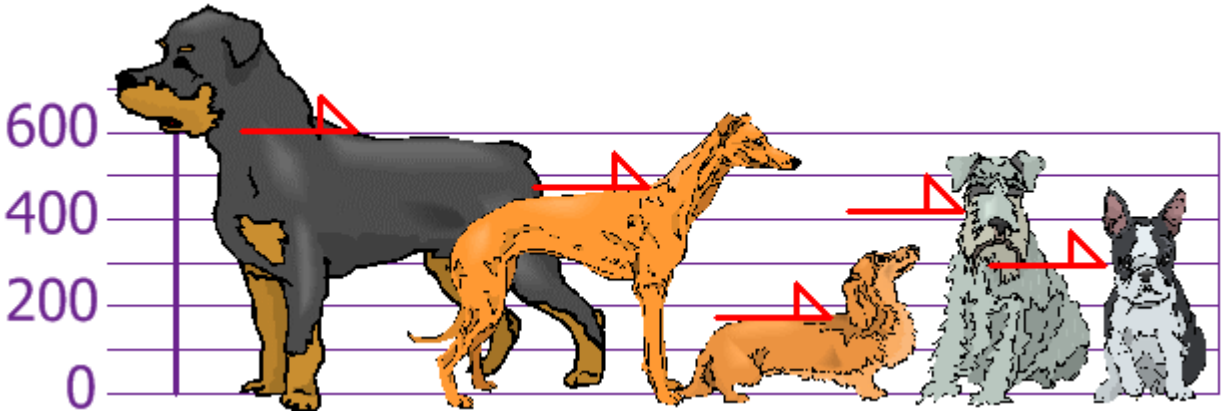


Leíró statisztika

- 1. momentum (várható érték) jellegű mutatók:
  - átlag = számtani közép = tapasztalati várható érték
  - medián (a középső érték)
  - módusz (leggyakrabban előforduló érték)
- 2. momentum (szórásnégyzet = variancia) jellegű mutatók:
  - Szórásnégyzet, szórás
  - adatterjedelem, min, max



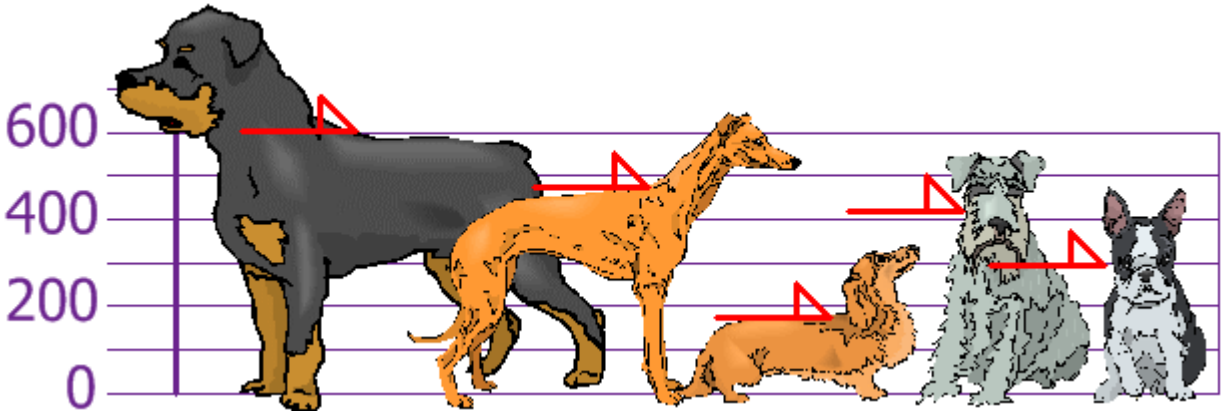
Példa: marmagasság



Adatok: 600, 470, 170, 430, 300 (mm)

Példa: marmagasság

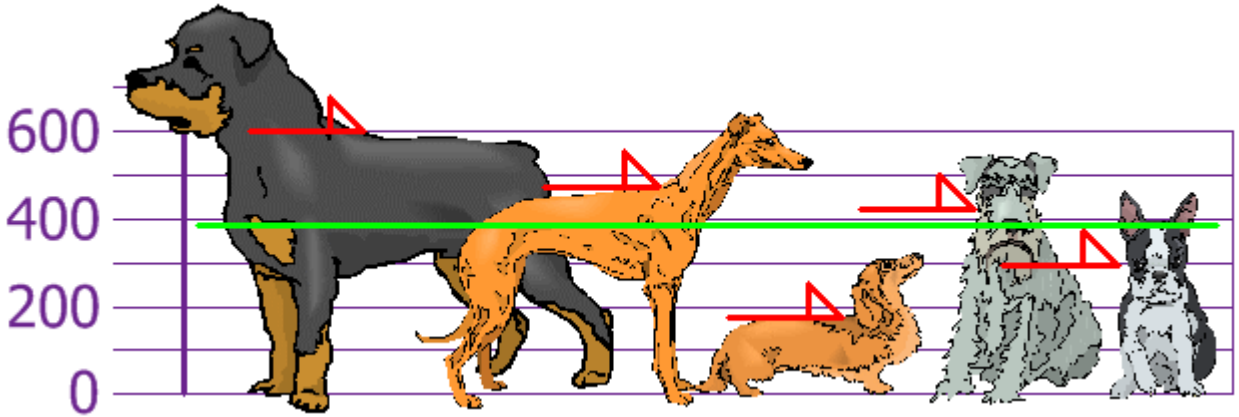
$$m = \frac{\sum_{i=1}^{n} x_i}{n} \qquad \sigma^2 = \frac{\sum_{i=1}^{n} (x_i - m)^2}{n}$$



Adatok: 600, 470, 170, 430, 300 (mm)

Példa: marmagasság

$$m = \frac{\sum_{i=1}^{n} x_i}{n} \qquad \sigma^2 = \frac{\sum_{i=1}^{n} (x_i - m)^2}{n}$$

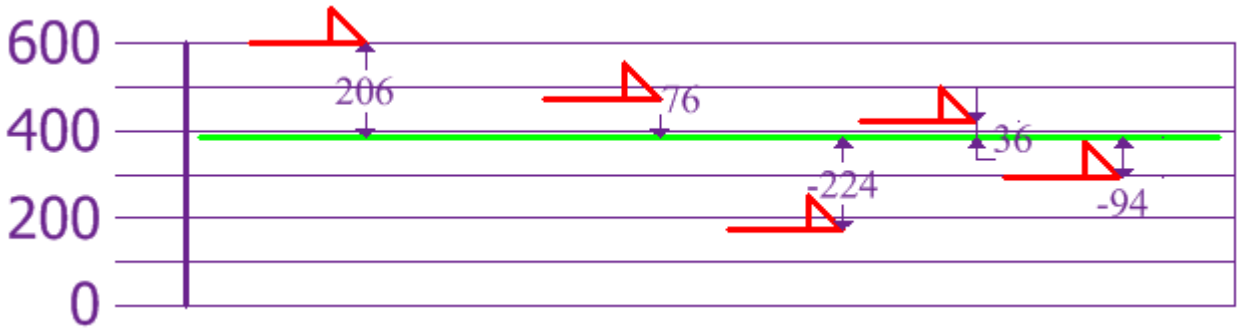


átlag: 394 mm

Adatok: 600, 470, 170, 430, 300 (mm)

Példa: marmagasság

$$m = \frac{\sum_{i=1}^{n} x_i}{n} \qquad \sigma^2 = \frac{\sum_{i=1}^{n} (x_i - m)^2}{n}$$



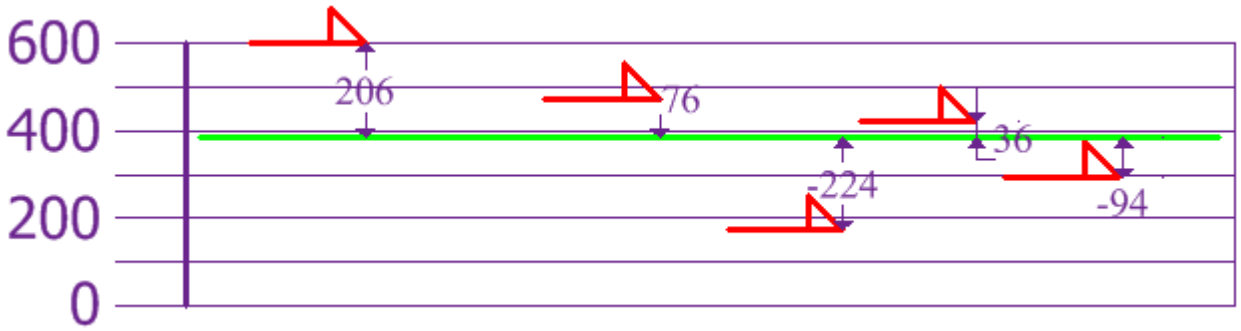
átlag: 394 mm

Adatok: 600, 470, 170, 430, 300 (mm)

Átlagtól való eltérés: 206, 76, -224, 36, -94 (mm)

Példa: marmagasság

$$m = \frac{\sum_{i=1}^{n} x_i}{n} \qquad \sigma^2 = \frac{\sum_{i=1}^{n} (x_i - m)^2}{n}$$



átlag: 394 mm

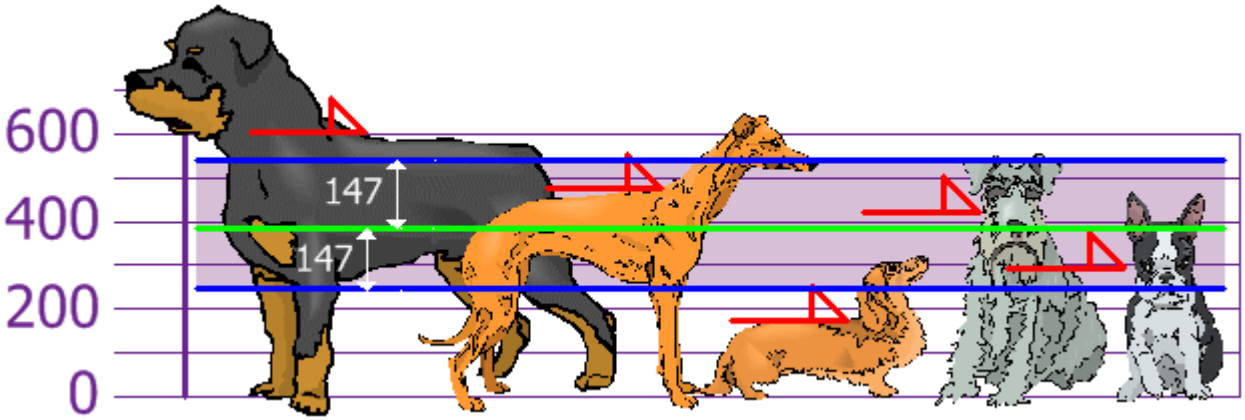
Adatok: 600, 470, 170, 430, 300 (mm)

Átlagtól való eltérés: 206, 76, -224, 36, -94 (mm)

$\sigma^2 = ((206)^2 + (76)^2 + (-224)^2 + (36)^2 + (-94)^2) / 5 = 21704$ (mm^2)

Példa: marmagasság

$$m = \frac{\sum_{i=1}^{n} x_i}{n} \qquad \sigma^2 = \frac{\sum_{i=1}^{n} (x_i - m)^2}{n}$$



átlag: 394 mm
szórás: 147.3 mm

Adatok: 600, 470, 170, 430, 300 (mm)

Átlagtól való eltérés: 206, 76, -224, 36, -94 (mm)

$\sigma^2 = ((206)^2 + (76)^2 + (-224)^2 + (36)^2 + (-94)^2) / 5 = 21704$ (mm^2)

$\sigma = 147.3$ (mm)

1. gyakorlat: horoszkop.csv elemzése

- https://colab.research.google.com/
- Olvassuk be az adatokat: https://ruzsaz.github.io/horoszkop.csv
- Ezek a 2010.01.01 – 2022.04.30 között elhunyt, magyar taj számmal rendelkezők adatai:
  szul_ev: a születés éve,
  szul_ho: a születés hónapja,
  kor: élt napok száma
- Számoljuk ki a leíró statisztikákat: átlag, szórás, medián, stb...



```python
import pandas as pd

# Pandas formázás beállítása, hogy ne exponenciális formátumot használjon
pd.set_option('display.float_format', lambda x: '%.4f' % x)

# CSV fájl beolvasása
url = "https://ruzsaz.github.io/horoszkop.csv"
df = pd.read_csv(url)

# Első 10 sor kiírása
print("Az első 10 sor:")
display(df.head(10))

# Leíró statisztika
print("\nLeíró statisztika:")
display(df.describe(include='all'))
```

Leíró statisztika:

	szul_ev	szul_ho	kor
count	1623658.0000	1623658.0000	1623658.0000
mean	1941.4462	6.4220	27156.6846
std	14.2593	3.4024	5090.2943
min	1901.0000	1.0000	-13.0000
25%	1931.0000	3.0000	23996.0000
50%	1939.0000	6.0000	27983.0000
75%	1951.0000	9.0000	30985.0000
max	2022.0000	12.0000	41338.0000



Barnóczki Brigitta

Másolás 2082

A Republikon Intézet legfrissebb kutatása szerint januárban hibahatáron belül tovább nőtt a Tisza Párt előnye a Fidesz–KDNP-vel szemben, a teljes népesség körében 3 százalékponttal vezet Magyar Péter pártja, 26 százalékpont a támogatottsága a Fidesz–KDNP 23-as eredményével szemben. Az MSZP-közeli intézet reprezentatív kutatása szerint a pártválasztók körében 37 százalék szavazna a Tiszára, 32 pedig a Fidesz–KDNP-re.

Módszertan: A kutatás 1000 fő telefonos megkérdezésével készült 2025. január 14–22. között. A kutatás nem, életkor, iskolai végzettség és településtípus szerint reprezentatív az ország felnőtt lakosságára. A hibahatár: +/- 3,2%.

Az intézet oldalán is elérhető kutatás szerint a vizsgált időszakban 39-32 volt az állás a biztos szavazó pártválasztók körében, ami az intézet szerint azt jelenti,

telex
Kövess minket Faceboo
Követem!

Legfontosabb


KÜLFÖLD
Mire a tűzoltó
a negyedik és
emeletek már
emberek a fel
szinteken sik


A modern kor
nyolcvan éve



Barnóczki Brigitta

Másolás 2082

A Republikon Intézet legfrissebb kutatása szerint januárban hibahatáron belül tovább nőtt a Tisza Párt előnye a Fidesz–KDNP-vel szemben, a teljes népesség körében 3 százalékponttal vezet Magyar Péter pártja, 26 százalékpont a támogatottsága a Fidesz–KDNP 23-as eredményével szemben. Az MSZP-közeli intézet reprezentatív kutatása szerint a pártválasztók körében 37 százalék szavazna a Tiszára, 32 pedig a Fidesz–KDNP-re.

Módszertan: A kutatás 1000 fő telefonos megkérdezésével készült 2025. január 14–22. között. A kutatás nem, életkor, iskolai végzettség és településtípus szerint reprezentatív az ország felnőtt lakosságára. A hibahatár: +/- 3,2%.

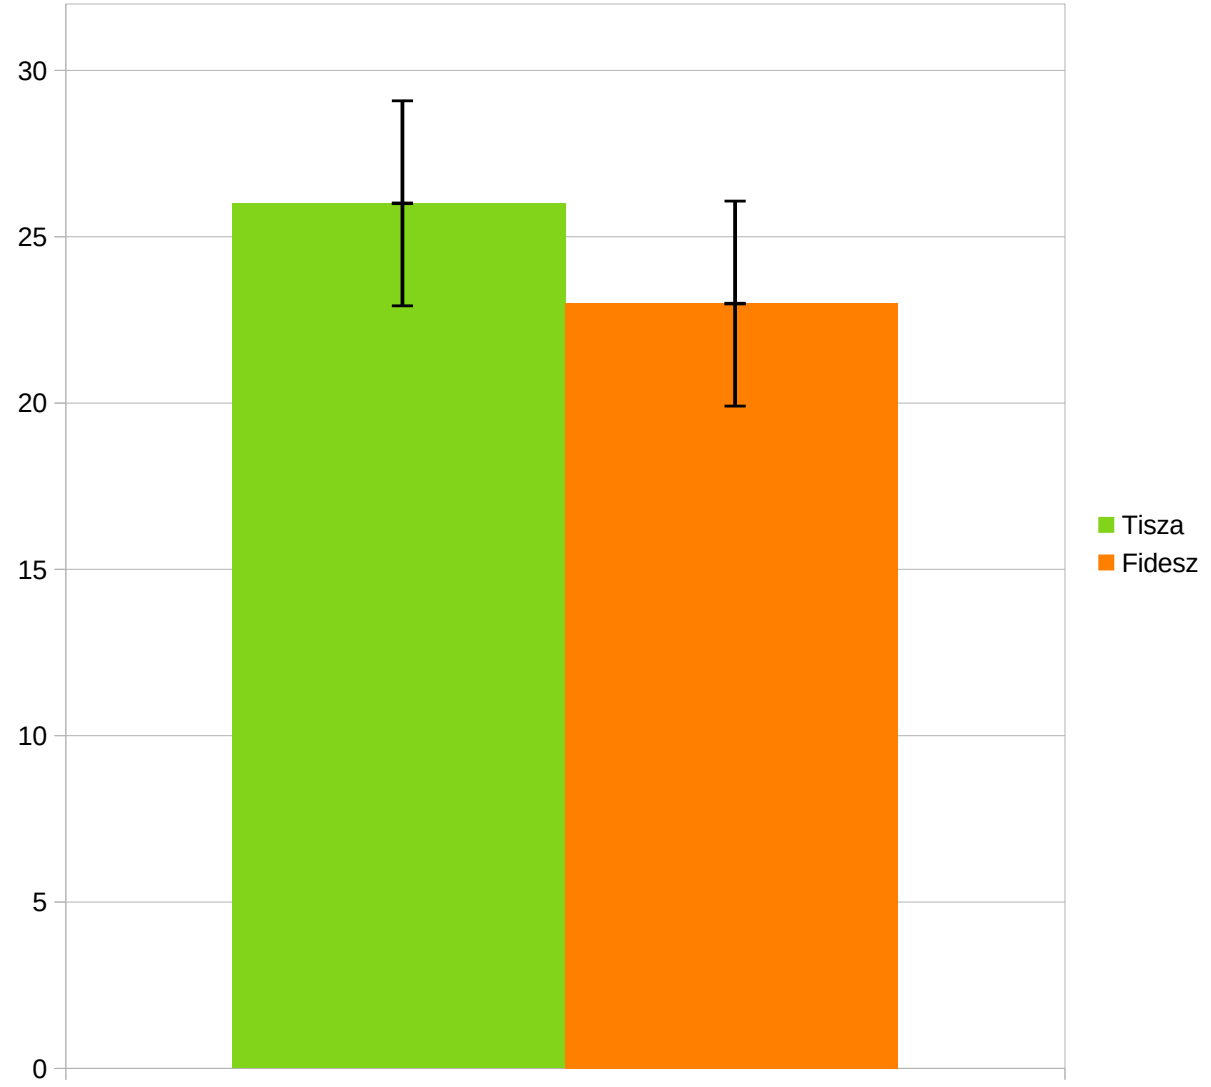
Az intézet oldalán is elérhető kutatás szerint a vizsgált időszakban 39-32 volt az állás a biztos szavazó pártválasztók körében, ami az intézet szerint azt jelenti, hogy a Tisza magabiztosan vezet, de a növekedési üteme lassult. Az intézet azt

telex
Kövess minket Faceboo
Követem!

Legfontosabb


KÜLFÖLD
Mire a tűzoltó
a negyedik és
emeletek már
emberek a fel
szinteken sik


A modern kor
nyolcvan éve



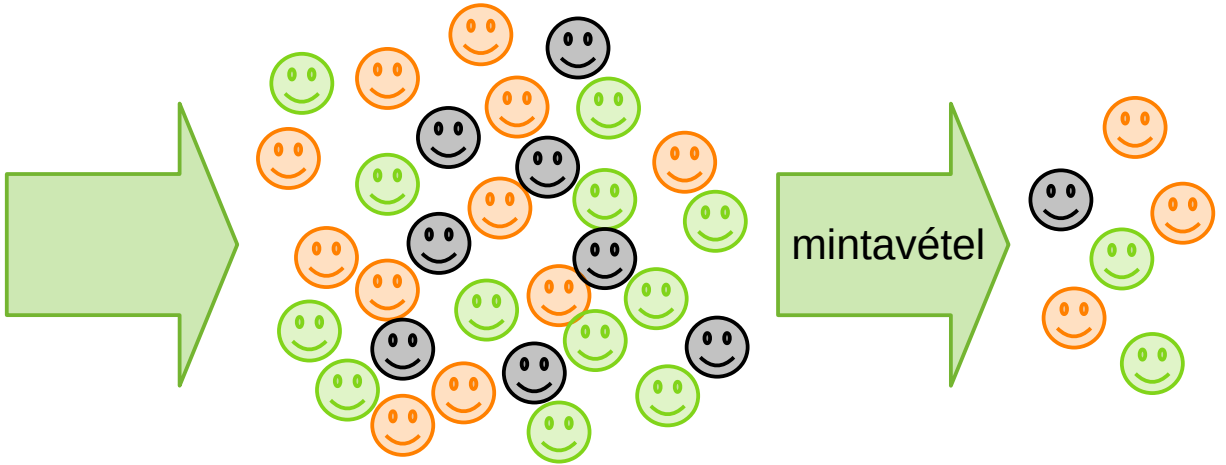
Tisza: 26%

Fidesz: 23%

hibahatár: +/- 3.2%

Valóság – matematikai modell – statisztika



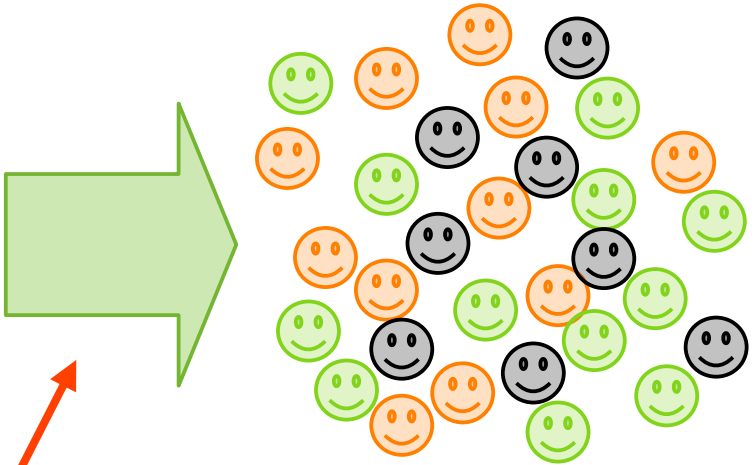


8.2M szavazópolgár

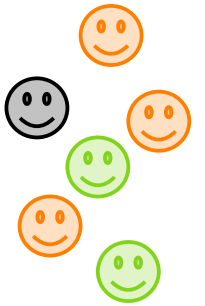
1000 fő

Valóság – matematikai modell – statisztika





mintavétel



8.2M szavazópolgár

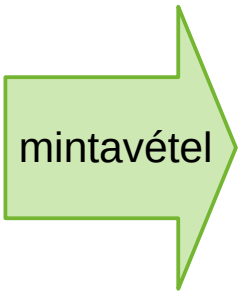
1000 fő

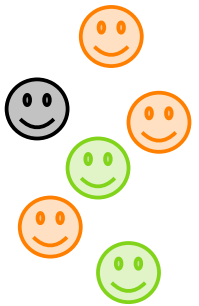
Módszertani hiba

Mintavételi hiba

Matematikai modell – statisztika







8.2M ember

- *f* -ed része Fideszre szavaz
- *t* -ed része Tiszára
- (1-*f*-*t*) -ed része egyéb

(*f* és *t* nem ismert paraméterek)

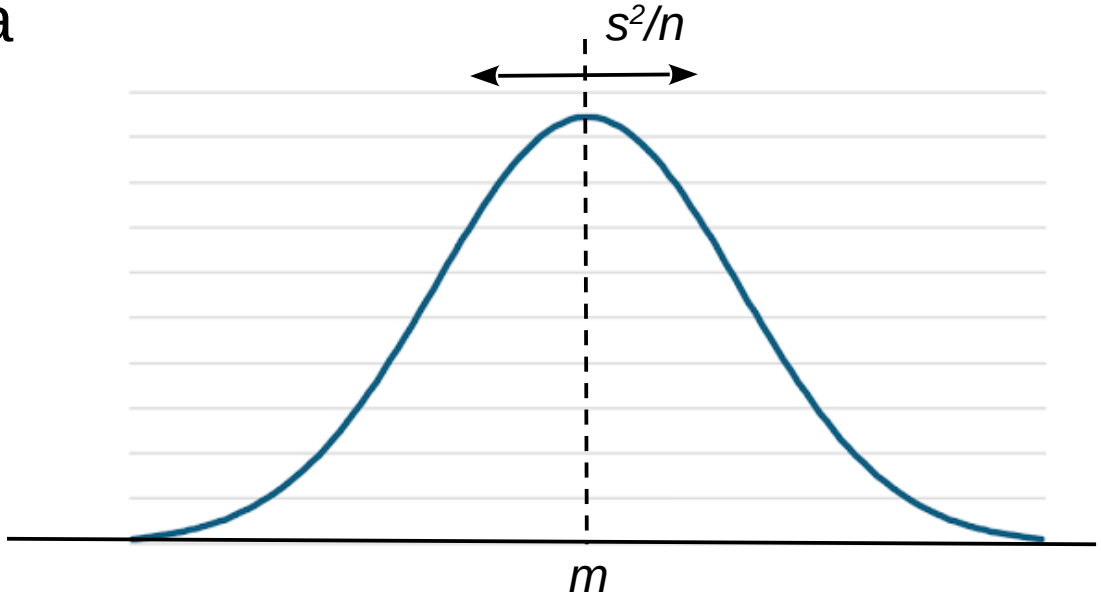
1000 fős minta

- tapasztalati becslés *f* -re
- tapasztalati becslés *t* -re

Centrális Határeloszlás Tétel

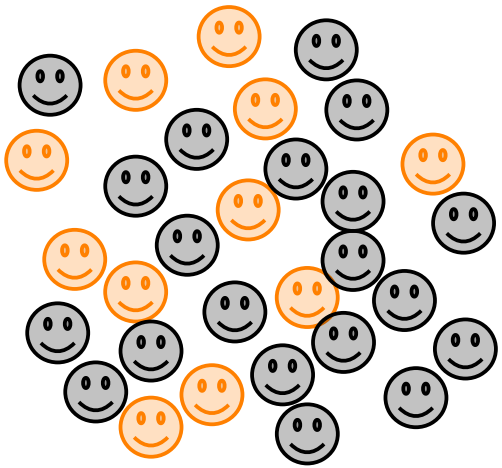
Bármilyen eloszlású valószínűségi változóból vett független minta átlaga közelítőleg normális eloszlású: $N(m, s^2/n)$, ahol

- m az eredeti változó várható értéke
- s az eredeti változó szórása
- n a minta elemszáma

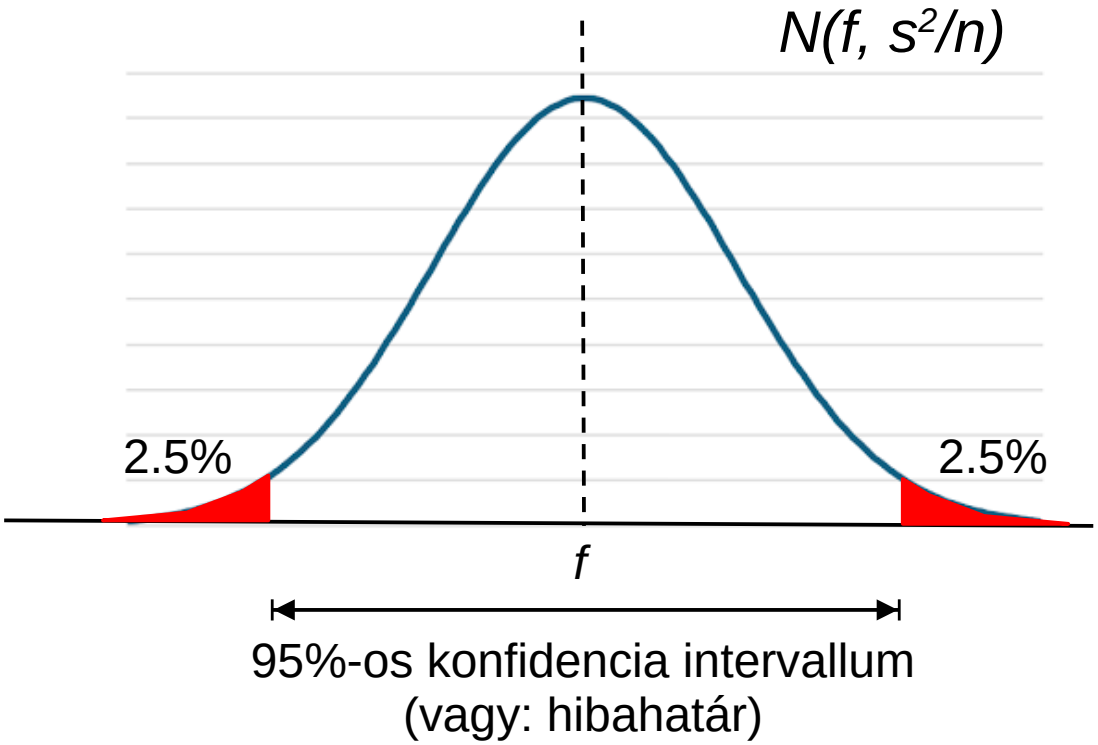


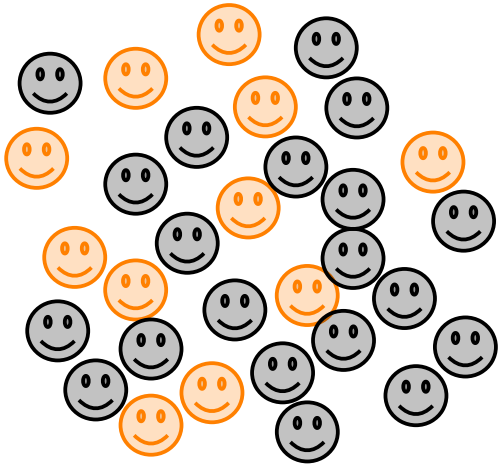
Konfidenciaszint → hibahatár

95% -os konfidenciaszint

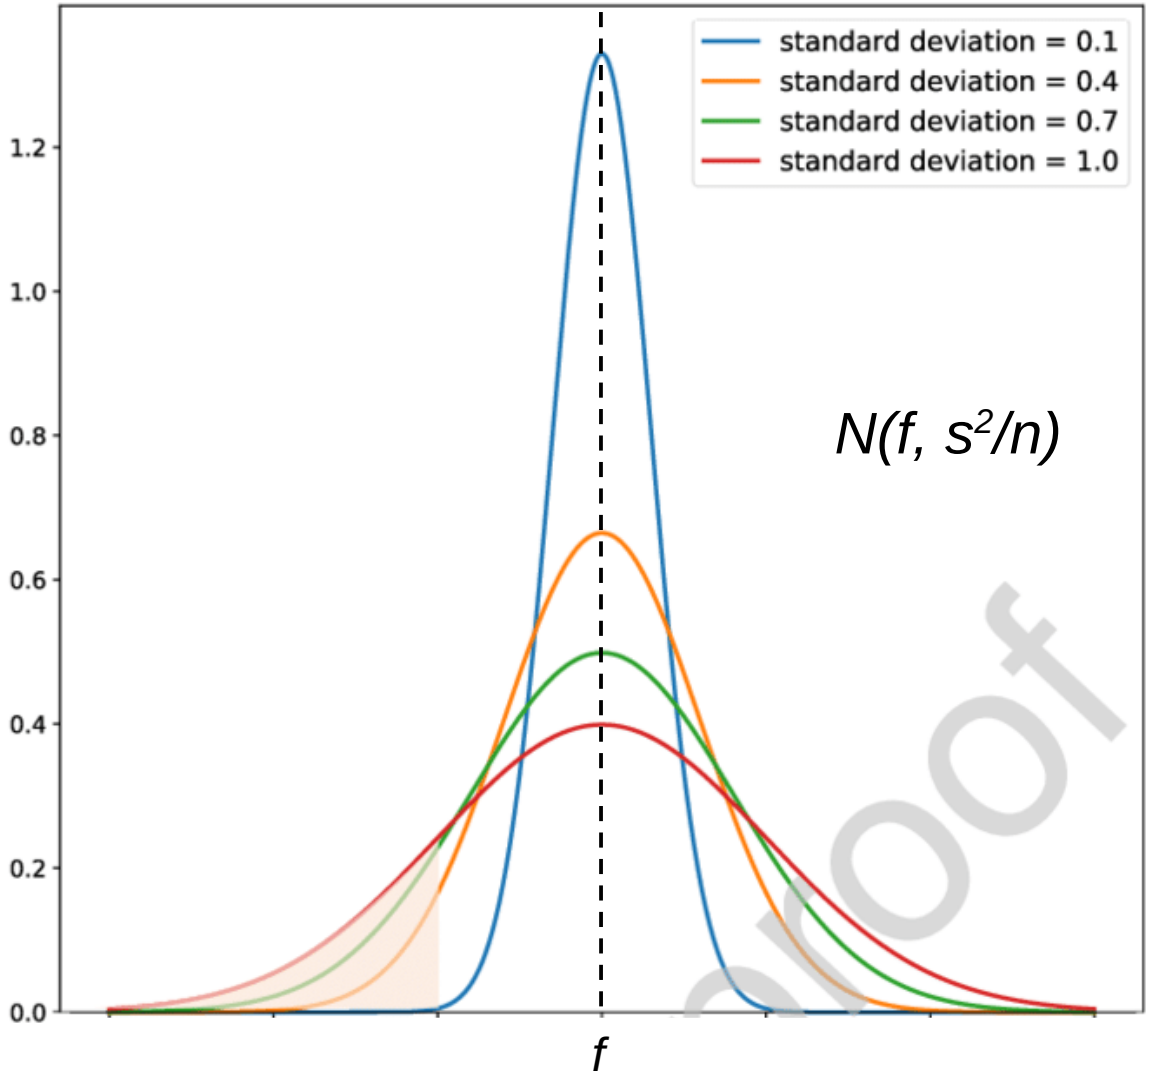


f -ed része Fideszre szavaz





f -ed része Fideszre szavaz





Barnóczki Brigitta

Másolás 2082

A Republikon Intézet legfrissebb kutatása szerint januárban hibahatáron belül tovább nőtt a Tisza Párt előnye a Fidesz–KDNP-vel szemben, a teljes népesség körében 3 százalékponttal vezet Magyar Péter pártja, 26 százalékpont a támogatottsága a Fidesz–KDNP 23-as eredményével szemben. Az MSZP-közeli intézet reprezentatív kutatása szerint a pártválasztók körében 37 százalék szavazna a Tiszára, 32 pedig a Fidesz–KDNP-re.

Módszertan: A kutatás 1000 fő telefonos megkérdezésével készült 2025. január 14–22. között. A kutatás nem, életkor, iskolai végzettség és településtípus szerint reprezentatív az ország felnőtt lakosságára. A hibahatár: +/- 3,2%.

Az intézet oldalán is elérhető kutatás szerint a vizsgált időszakban 39-32 volt az állás a biztos szavazó pártválasztók körében, ami az intézet szerint azt jelenti, hogy a Tisza magabiztosan vezet, de a növekedési üteme lassult. Az intézet azt

telex
Kövess minket Faceboo
Követem!

Legfontosabb


KÜLFÖLD
Mire a tűzoltó
a negyedik és
emeletek már
emberek a fel
szinteken sik


A modern kor
nyolcvan éve

Konfidencia → hibahatár

Ha csökkentjük az elvárt kofidenciát, a hibahatár ...



2. gyakorlat: vas.csv elemzése

- https://colab.research.google.com/
- https://ruzsaz.github.io/vas.csv
- Vegyünk egy véletlen 1000 fős mintát, és határozzuk meg a mintában a Tisza támogatottságát.
- Számoljuk ki a 95%-os konfidencia intervallumot.





[1]
✓ 1 mp

```python
import pandas as pd
import numpy as np
import scipy.stats as stats

# 1. Beolvasás
url_vas = "https://ruzsaz.github.io/vas.csv"
df_vas = pd.read_csv(url_vas)

# 2. Profilozás
print("--- Adatkeret infó ---")
display(df_vas.info())
print("\n--- Hiányzó értékek száma oszloponként ---")
display(df_vas.isnull().sum())
print("\n--- Első 5 sor ---")
display(df_vas.head())
```

Rejtett kimenet megjelenítése

[17]
✓ 0 mp

```python
# 3. 1000 sor véletlenszerű kiválasztása (egyszerű véletlen minta)
random_state = 13  # reprodukálhatóság érdekében
sample_df = df_vas.sample(n=1000, random_state=random_state) if len(df_vas) >= 1000 else df_vas.sample(n=len(df_vas), random_state=random_state)

# 4. 'tisza' szavazatok megszámlálása és relatív gyakorisága a mintában
n = len(sample_df)
tisza_count = (sample_df['szavazat'] == 'tisza').sum()
p_hat = tisza_count / n

# 5. 95%-os konfidenciaintervallum kiszámítása (Normal/Wald approximation vagy Wilson score)
# A Wald-féle konfidenciaintervallum képlete: p_hat +/- z * sqrt(p_hat * (1 - p_hat) / n)
z = stats.norm.ppf(0.975)  # 1.96 a 95%-os szinthez
se = np.sqrt(p_hat * (1 - p_hat) / n)
ci_lower = max(0.0, p_hat - z * se)
ci_upper = min(1.0, p_hat + z * se)

print(f"Minta mérete: {n}")
print(f"'tisza' szavazatok száma a mintában: {tisza_count}")
print(f"Relatív gyakoriság (pontbecslés): {p_hat:.4f} ({p_hat*100:.2f}%)")
print(f"95%-os konfidenciaintervallum: [{ci_lower:.4f}, {ci_upper:.4f}] ([{ci_lower*100:.2f}%, {ci_upper*100:.2f}%])")
```

Rejtett kimenet megjelenítése

Kinek mi jött ki?

Minta mérete: 1000

’tisza’ stavazatok száma a mintában: 384

Relatív gyakoriság (pontbecslés): 0.3840 (38.40%)

95%-os konf. Intervallum: [0.3539, 0.4141]



HF 1

Három közvélemény-kutató megmérte egy párt támogatottságát, az alábbi eredményekkel:

1) 36.2%, 600 fős minta
2) 29.8%, 2500 fős minta
3) 31.4%, 1000 fős minta

Ezek hibahatáron belüli eltérések?

Az eredmények összesítésével milyen eredményt kapunk? Milyen hibahatárral?




ARIES
TAURUS
GEMINI
CANCER
LEO
VIRGO
LIBRA
SCORPIO
SAGITTARIUS
CAPRICORN
AQUARIUS
PISCES

3. gyakorlat: horoszkop.csv elemzése

- https://ruzsaz.github.io/horoszkop.csv
- Számoljuk ki a várható élettartamot a saját születési hónapunkban születettekre. Mekkora a 95%-os konfidenciaintervallum?
- Alakítsuk függvénnyé az előzőt, számoljuk ki az összes hónapra, ábrázoljuk az eredményt.



```
 numpy as np
 pandas as pd
 scipy.stats as stats
 matplotlib.pyplot as plt

"https://ruzsaz.github.io/horoszkop.csv"
d.read_csv(url)

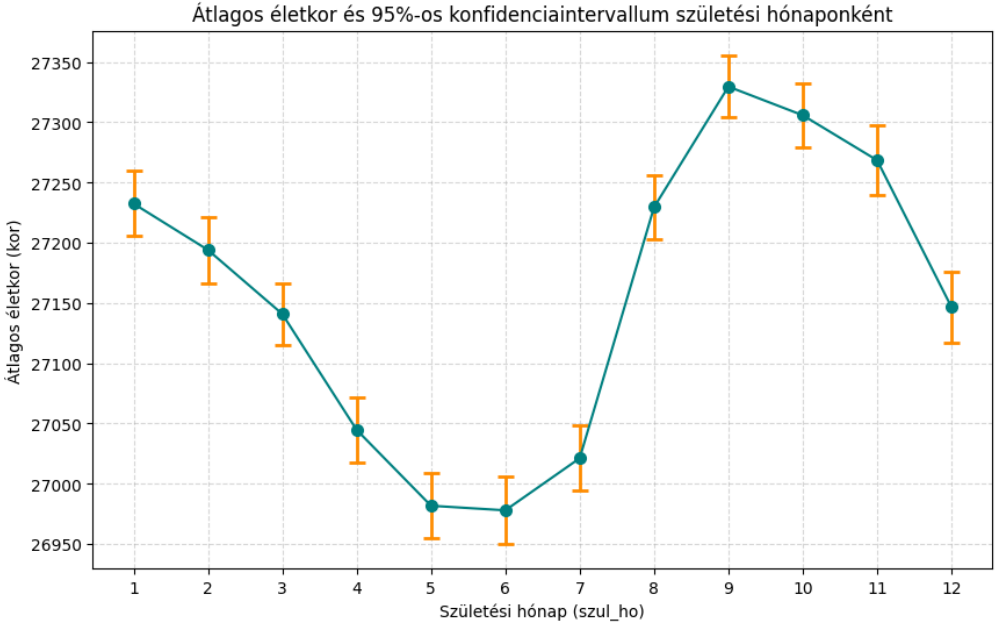
 = range(1, 13)
list = []

nth in months:
es = df[df['szul_ho'] == month]['kor'].dropna()
= len(ages)
an = ages.mean()
d_err = stats.sem(ages) if n > 1 else 0
= std_err * stats.t.ppf((1 + 0.95) / 2., n - 1) if n > 1 else 0    # 95%-os konfint
ats_list.append({'ho': month, 'kor': mean, 'cf_hossz': h, 'ci_also': mean - h, 'ci_felso': mean + h, 'meret': n})

df = pd.DataFrame(stats_list)
"Hónapok szerinti átlagos életkorok és 95%-os konfidenciaintervallumok:")
y(stats_df)

zolás hibasávokkal (errorbar)
gure(figsize=(10, 6))
rorbar(stats_df['szul_ho'], stats_df['atlag_kor'], yerr=stats_df['konf_intervallum_hossz'],
       fmt='o-', capsize=5, color='teal', ecolor='darkorange', elinewidth=2, markeredgewidth=2)
abel('Születési hónap (szul_ho)')
abel('Átlagos életkor (kor)')
tle('Átlagos életkor és 95%-os konfidenciaintervallum születési hónaponként')
icks(months)
id(True, linestyle='--', alpha=0.5)
ow()
```

	ho	kor	cf_hossz	ci_also	ci_felso	meret
0	1	27232.4747	27.0987	27205.3760	27259.5734	136099
1	2	27194.0748	27.4838	27166.5910	27221.5586	131131
2	3	27140.9250	25.7594	27115.1656	27166.6845	146376
3	4	27044.7198	26.8574	27017.8625	27071.5772	135835
4	5	26981.7501	26.7172	26955.0329	27008.4673	138692
5	6	26977.9449	27.9736	26949.9713	27005.9185	129043
6	7	27021.1934	27.0545	26994.1389	27048.2479	138284
7	8	27229.5188	26.1289	27203.3900	27255.6477	144321
8	9	27329.6229	25.7595	27303.8634	27355.3824	145285
9	10	27305.8406	26.9196	27278.9209	27332.7602	136750
10	11	27268.4843	29.0148	27239.4695	27297.4990	121129
11	12	27146.6176	29.3159	27117.3018	27175.9335	120713





Eldobott sorszámok:
9, 15, 16, 121, 206

Hány vásárló volt aznap?

German Tank Problem



German Tank Problem



4. gyakorlat: 9, 15, 16, 121, 206

- Mi a matematikai modell?
- https://en.wikipedia.org/wiki/German_tank_problem
- Ha m a maximális érték, k az elemszám, akkor a várható hibát minimalizáló torzítatlan becslés:

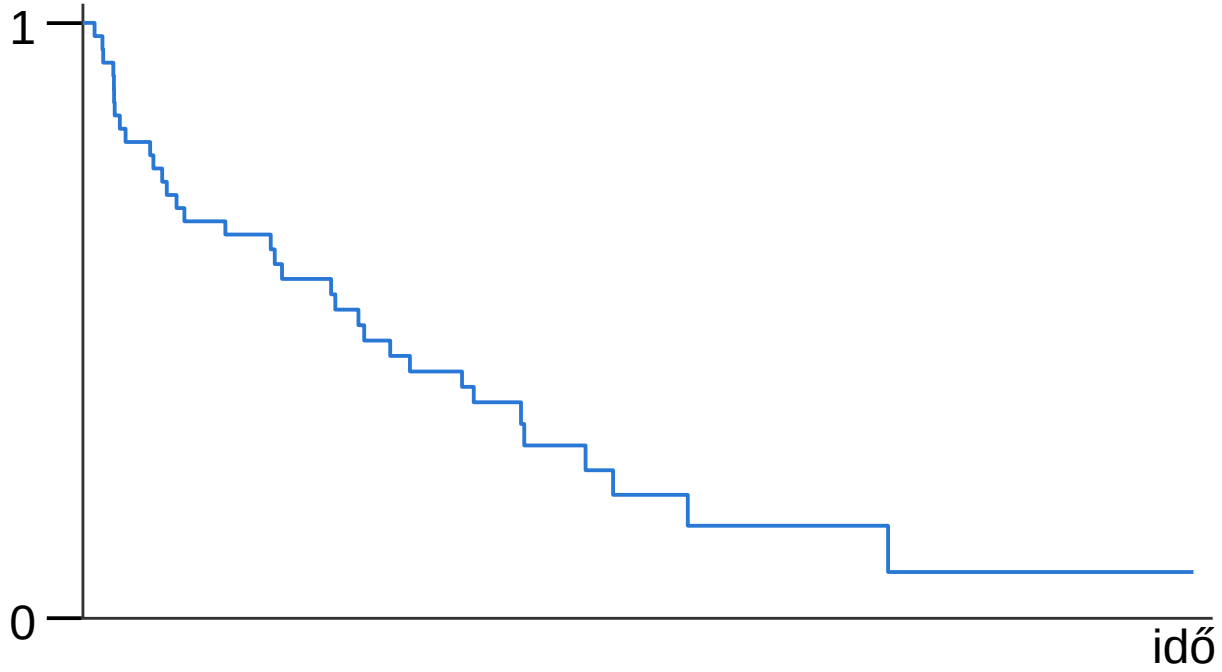
  $m(1+1/k) - 1$

  95%-os konfidencia-intervallum: $[m, m/0.05^{1/k}]$



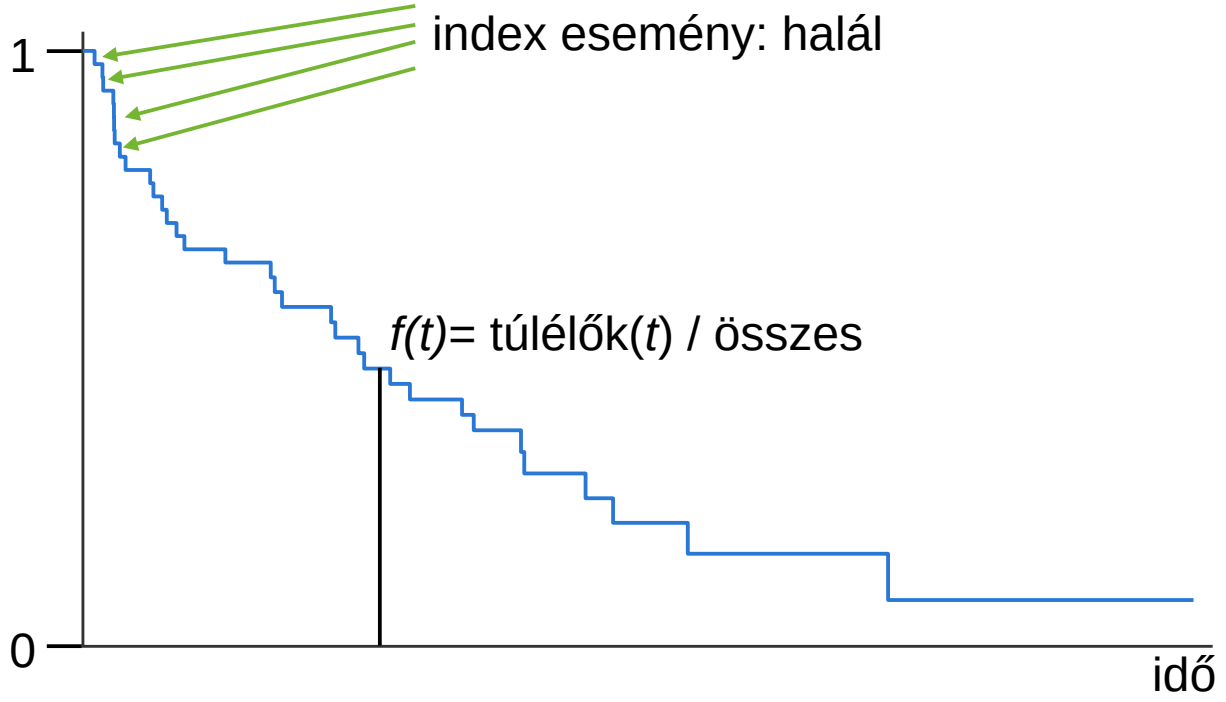
~~Kaplan-Meier~~ túlélési görbe

N=50 fő, túlélők száma
az idő függvényében



~~Kaplan-Meier~~ túlélési görbe

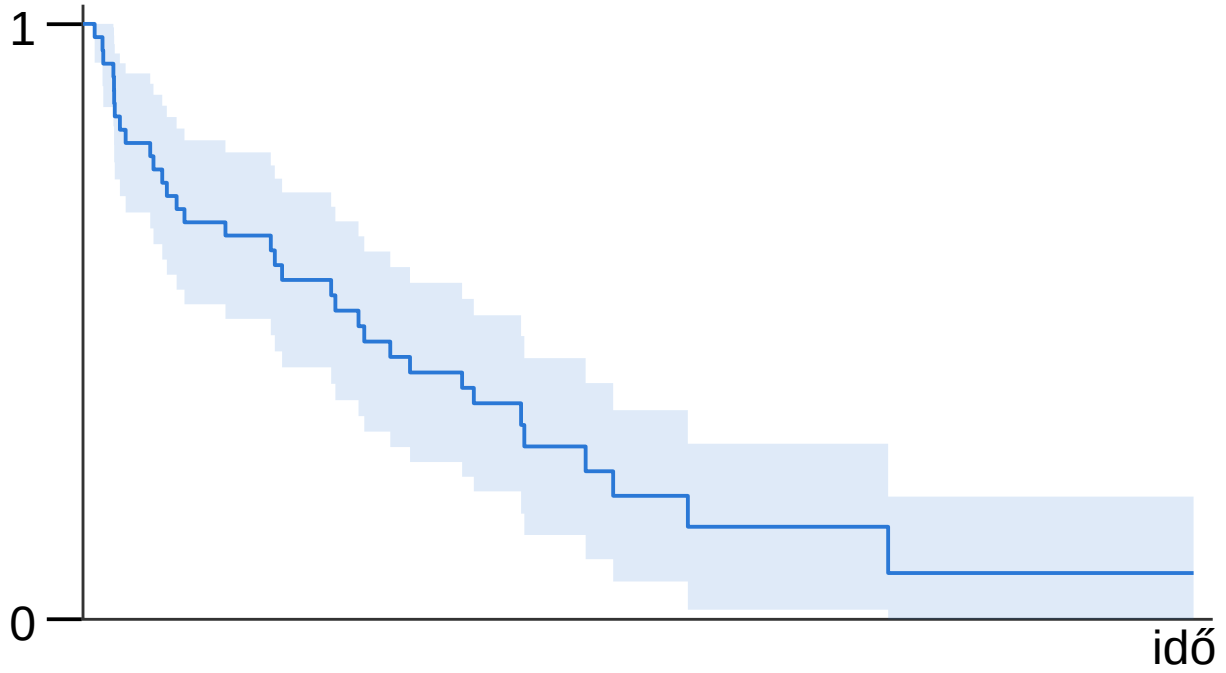
N=50 fő, túlélők száma
az idő függvényében



~~Kaplan-Meier~~ túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

+ 95%-os konfidencia sáv

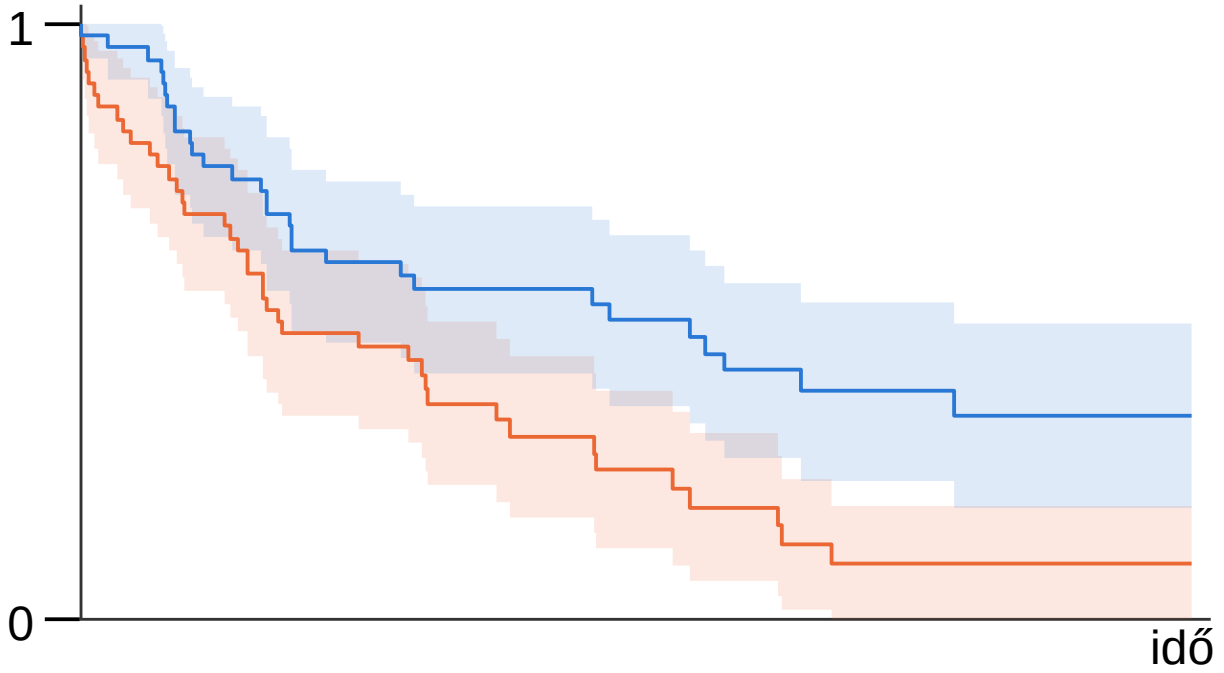


~~Kaplan-Meier~~ túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

+ 95%-os konfidencia sáv

Placebo Gyógyszer

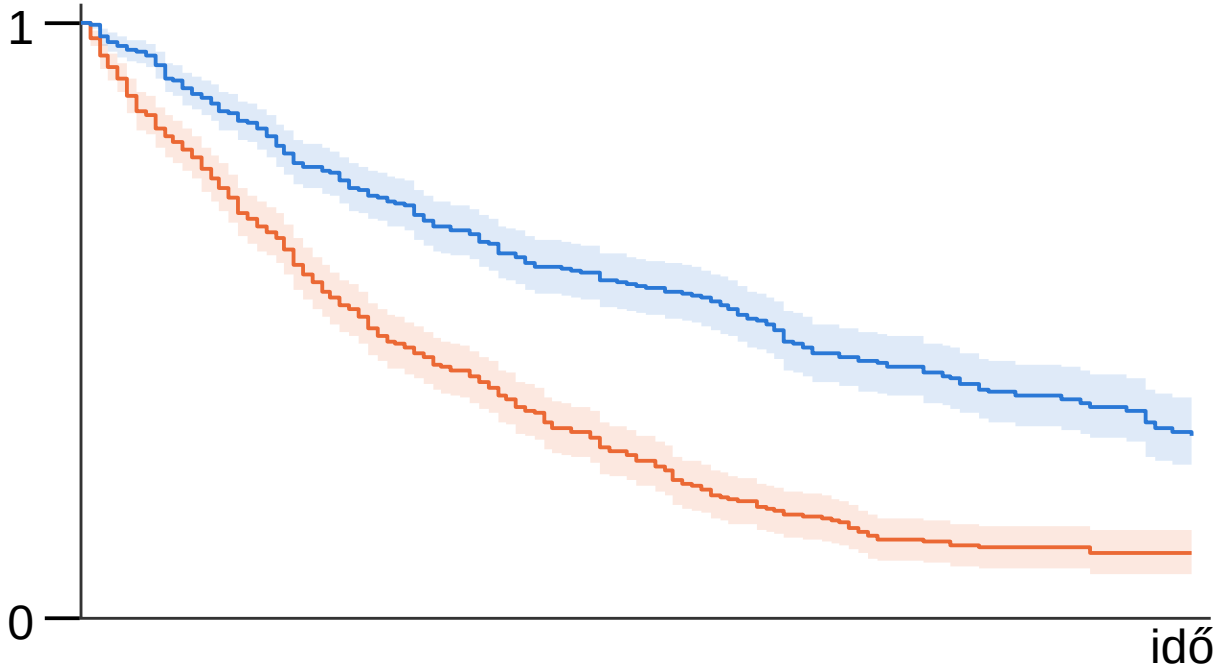


~~Kaplan-Meier~~ túlélési görbe

N=500 fő, túlélők száma
az idő függvényében

+ 95%-os konfidencia sáv

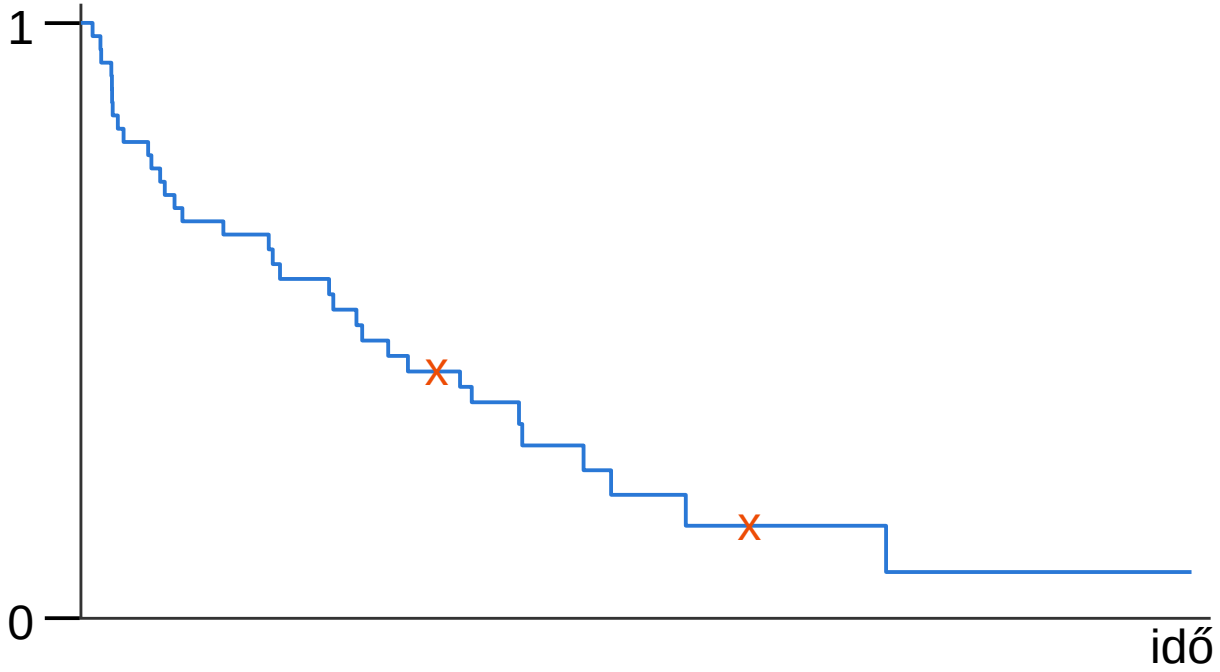
Placebo Gyógyszer



Kaplan-Meier túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

x: két beteg eltűnt

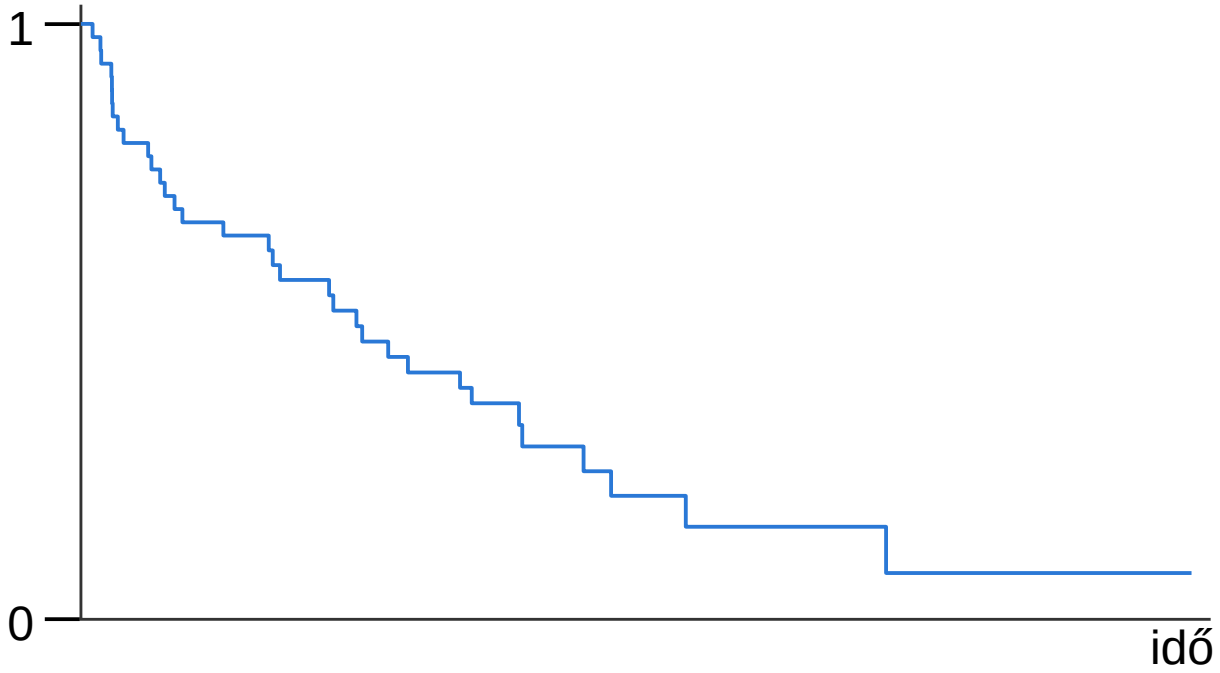


Kaplan-Meier túlélési görbe

N=48 fő, túlélők száma az idő függvényében

~~x: két beteg eltűnt~~

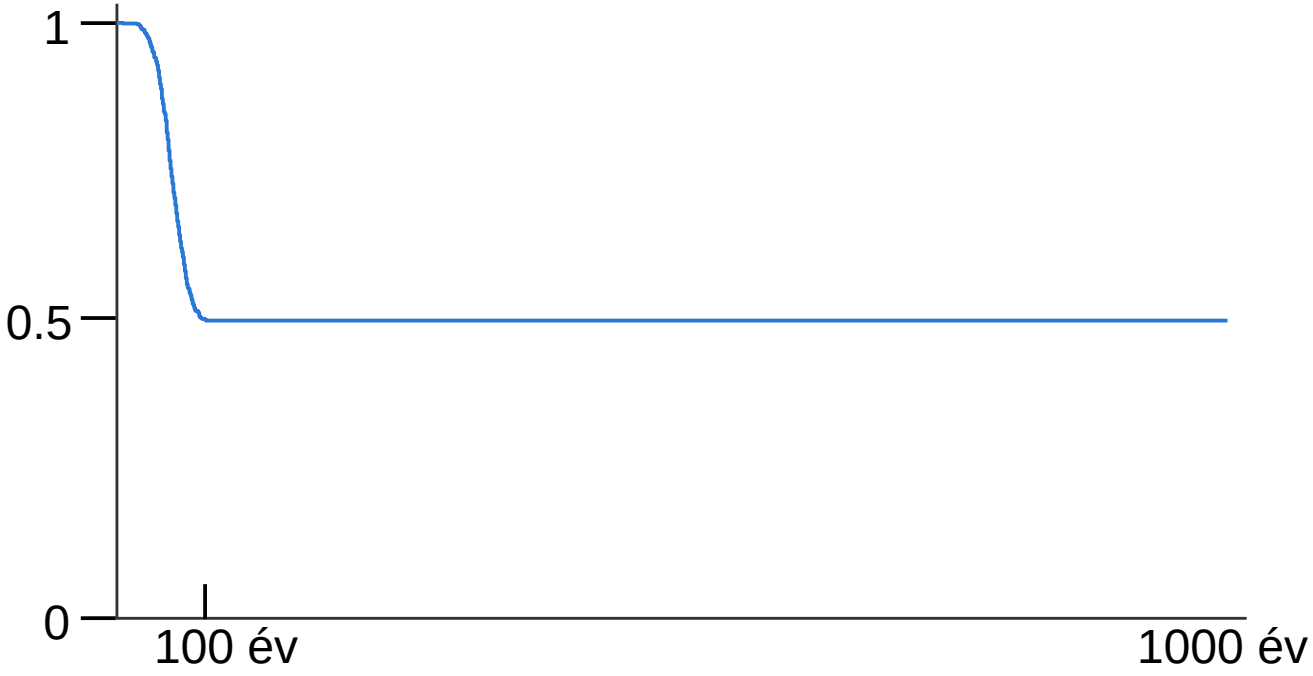
Hazugság!



Kaplan-Meier túlélési görbe

N=1000 fő

Örök élet gyógyszerteszt

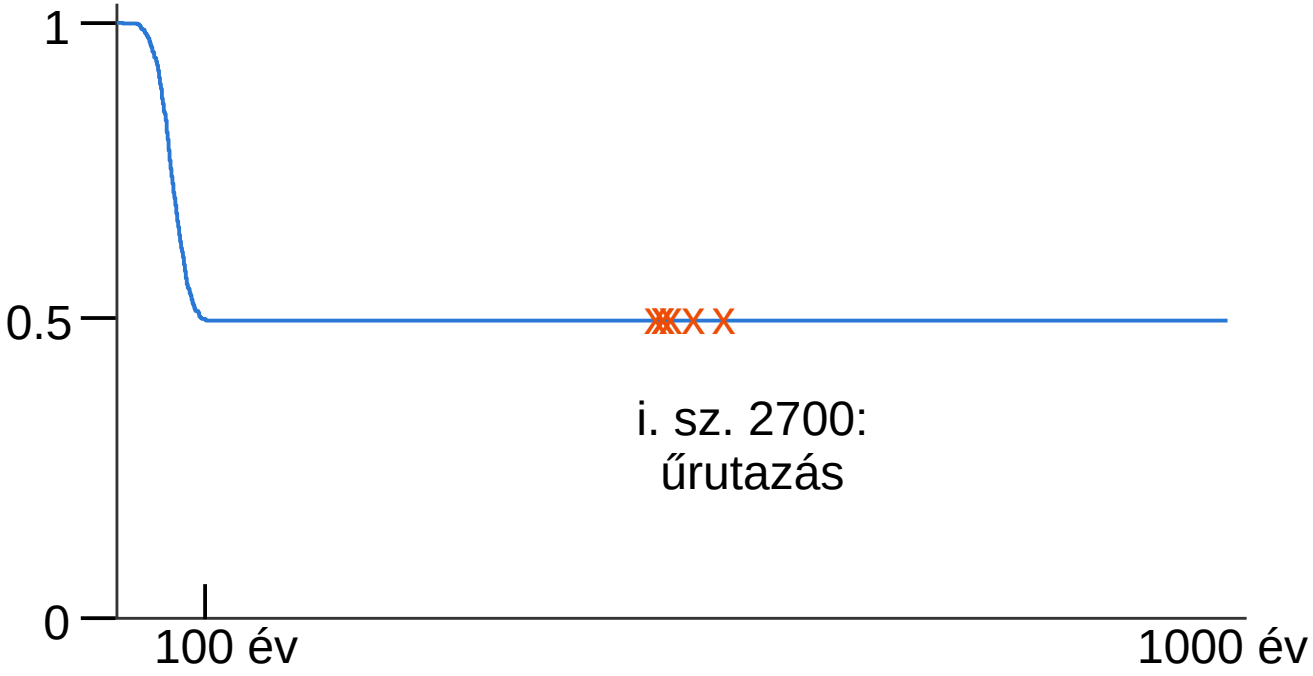


Kaplan-Meier túlélési görbe

N=1000 fő

Örök élet gyógyszerteszt

x: minden túlélő eltűnt



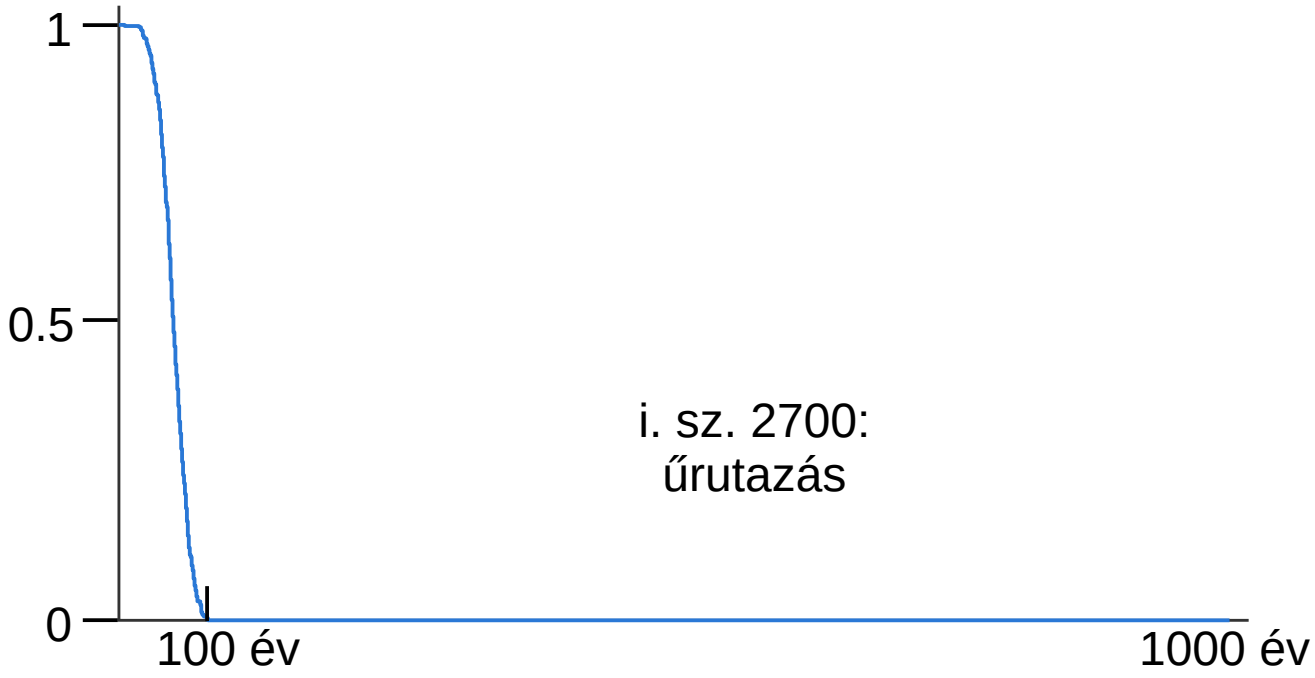
Kaplan-Meier túlélési görbe

N=500 fő

Örök élet gyógyszerteszt

~~x: minden túlélő eltűnt~~

Hazugság!

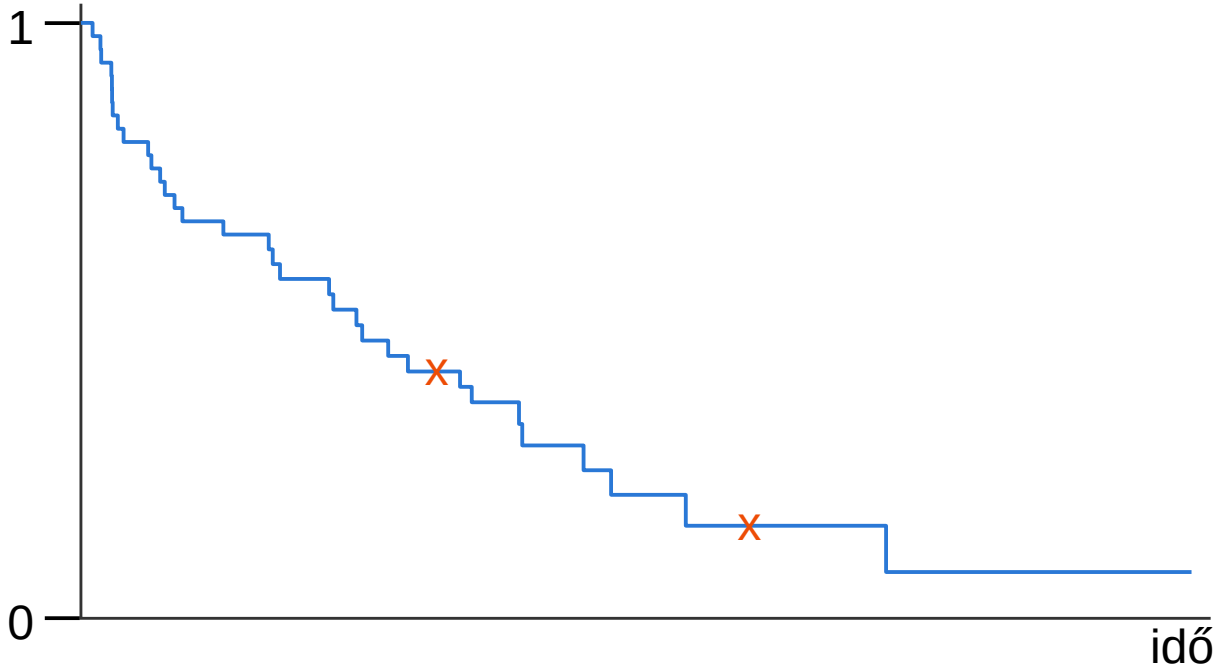


i. sz. 2700:
űrutazás

Kaplan-Meier túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

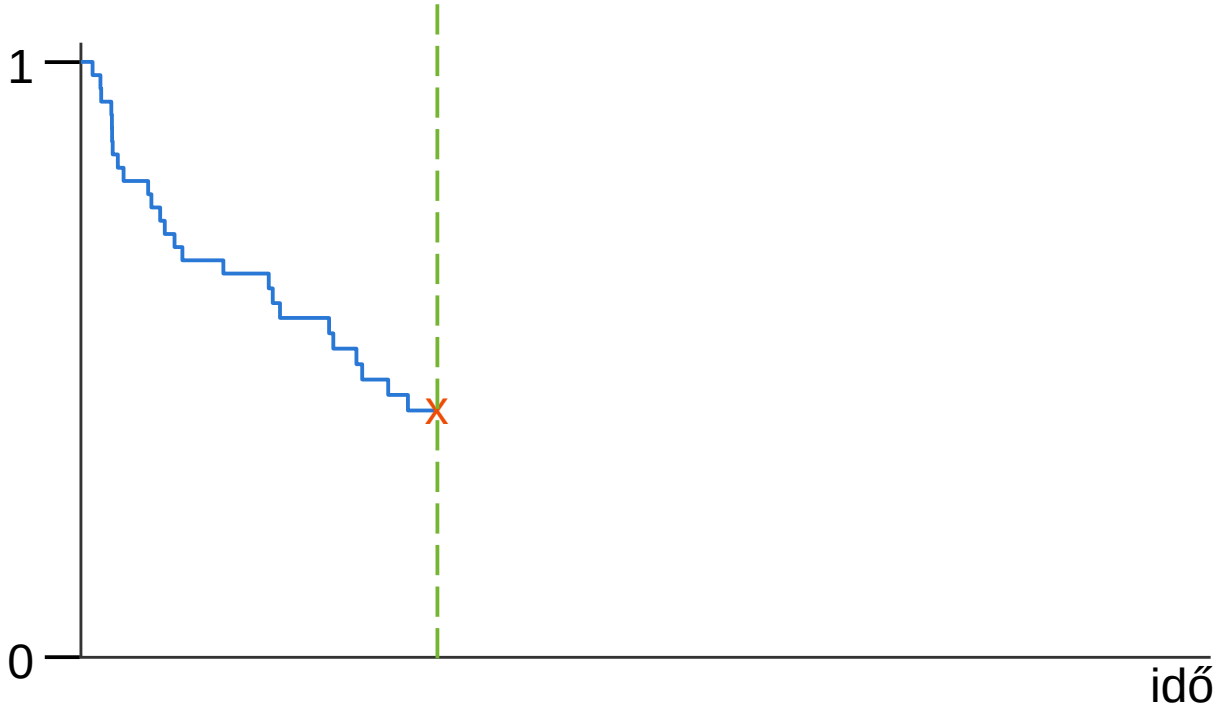
x: két beteg eltűnt



Kaplan-Meier túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

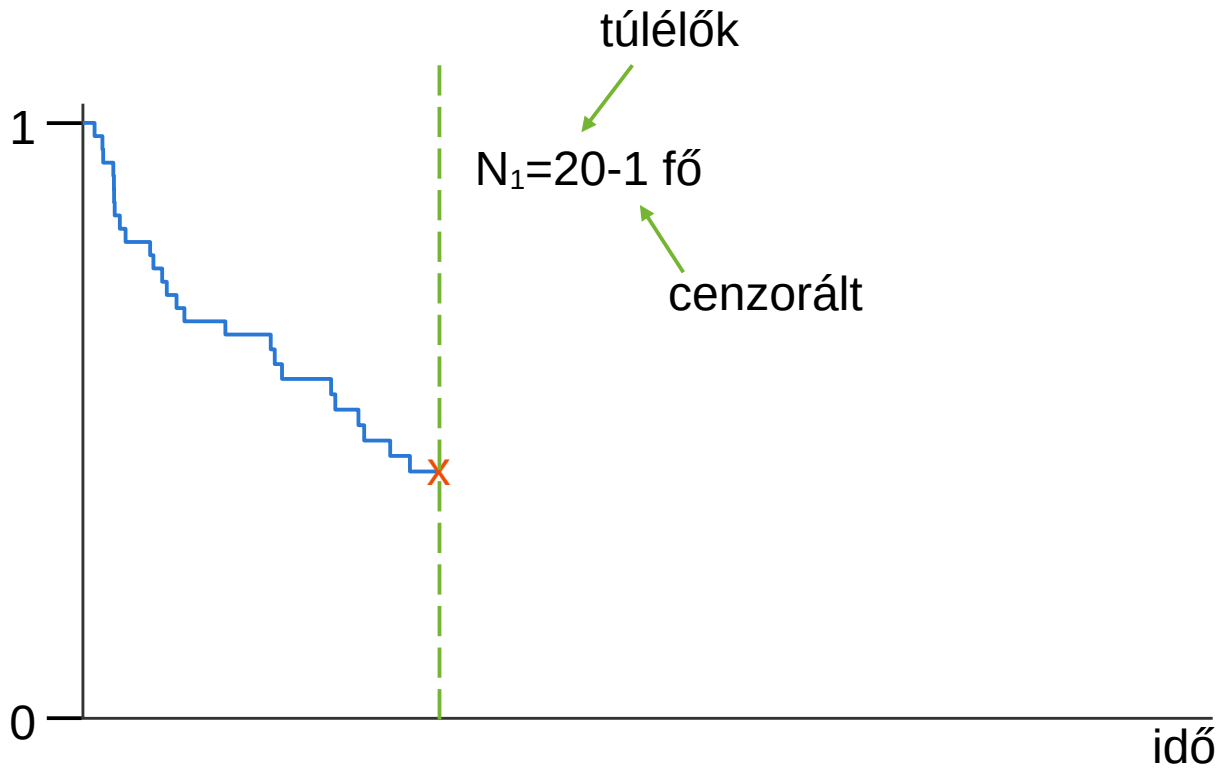
x: két beteg eltűnt



Kaplan-Meier túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

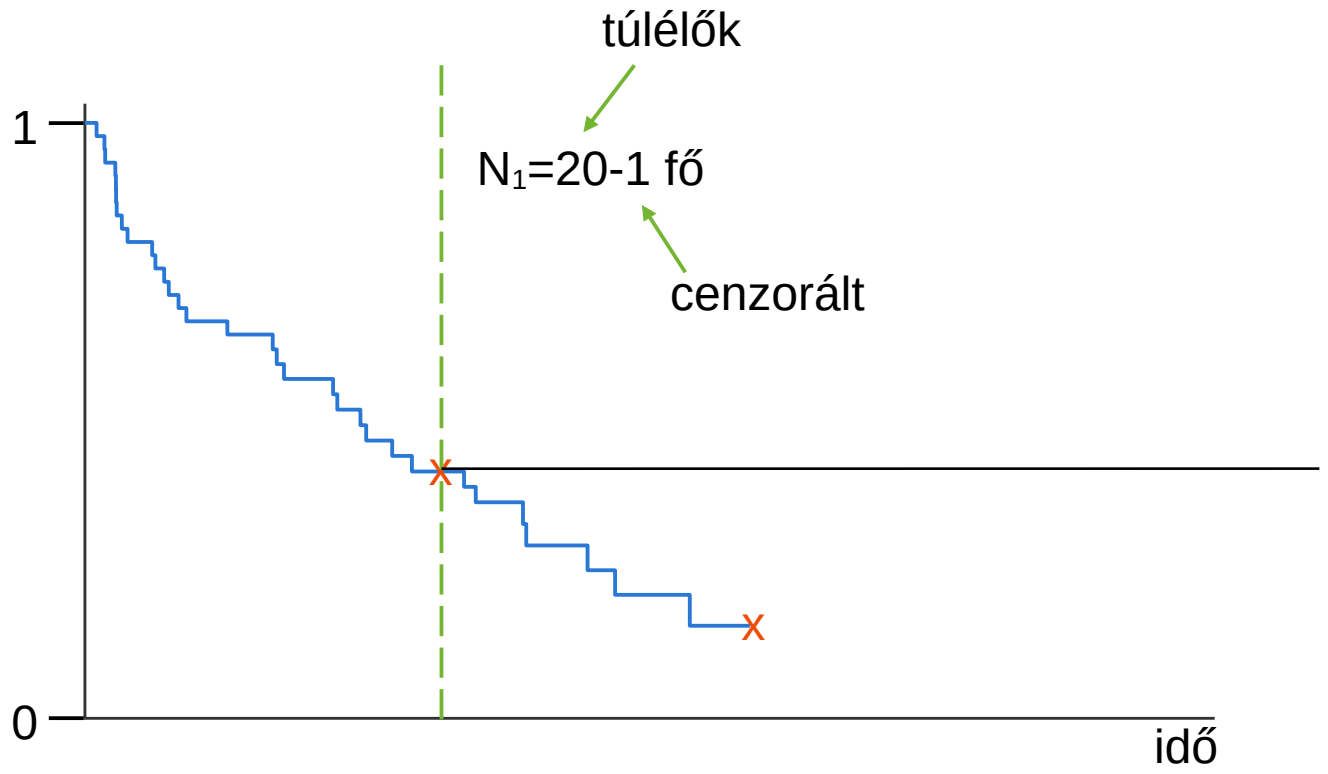
N_1=20-1 fő



Kaplan-Meier túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

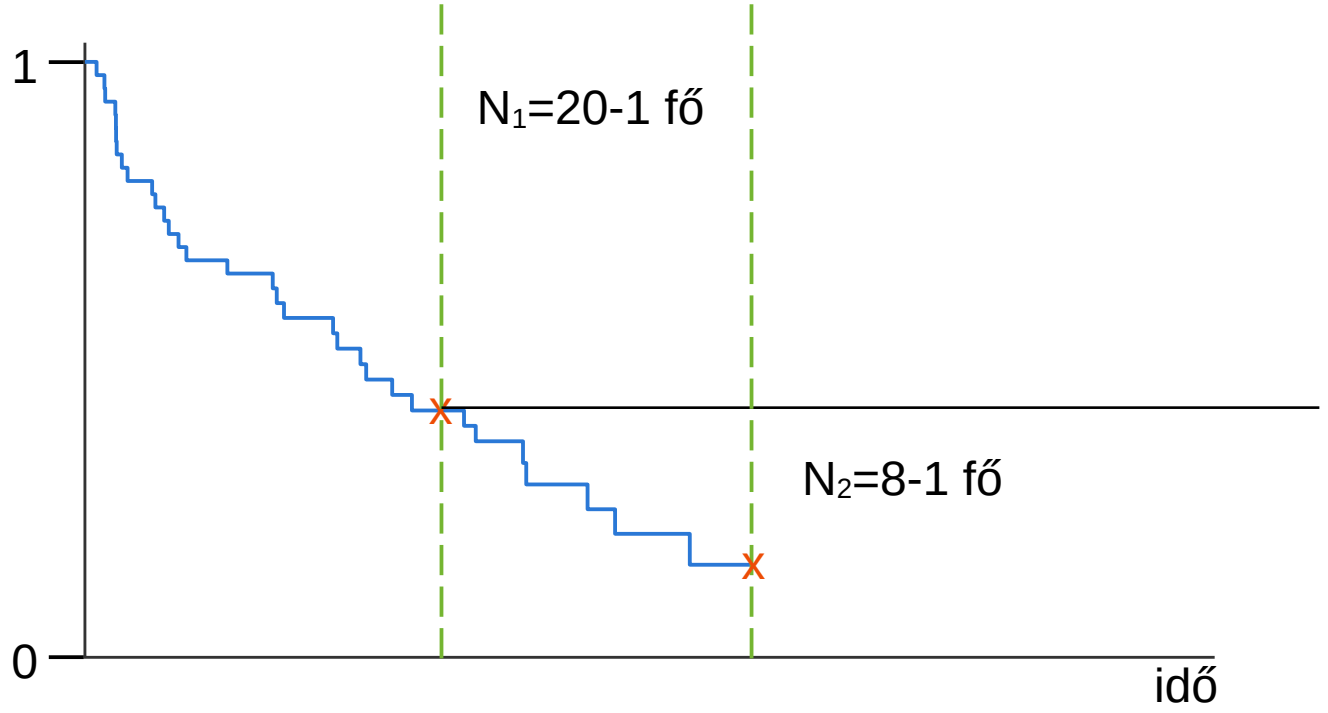
N_1=20-1 fő



Kaplan-Meier túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

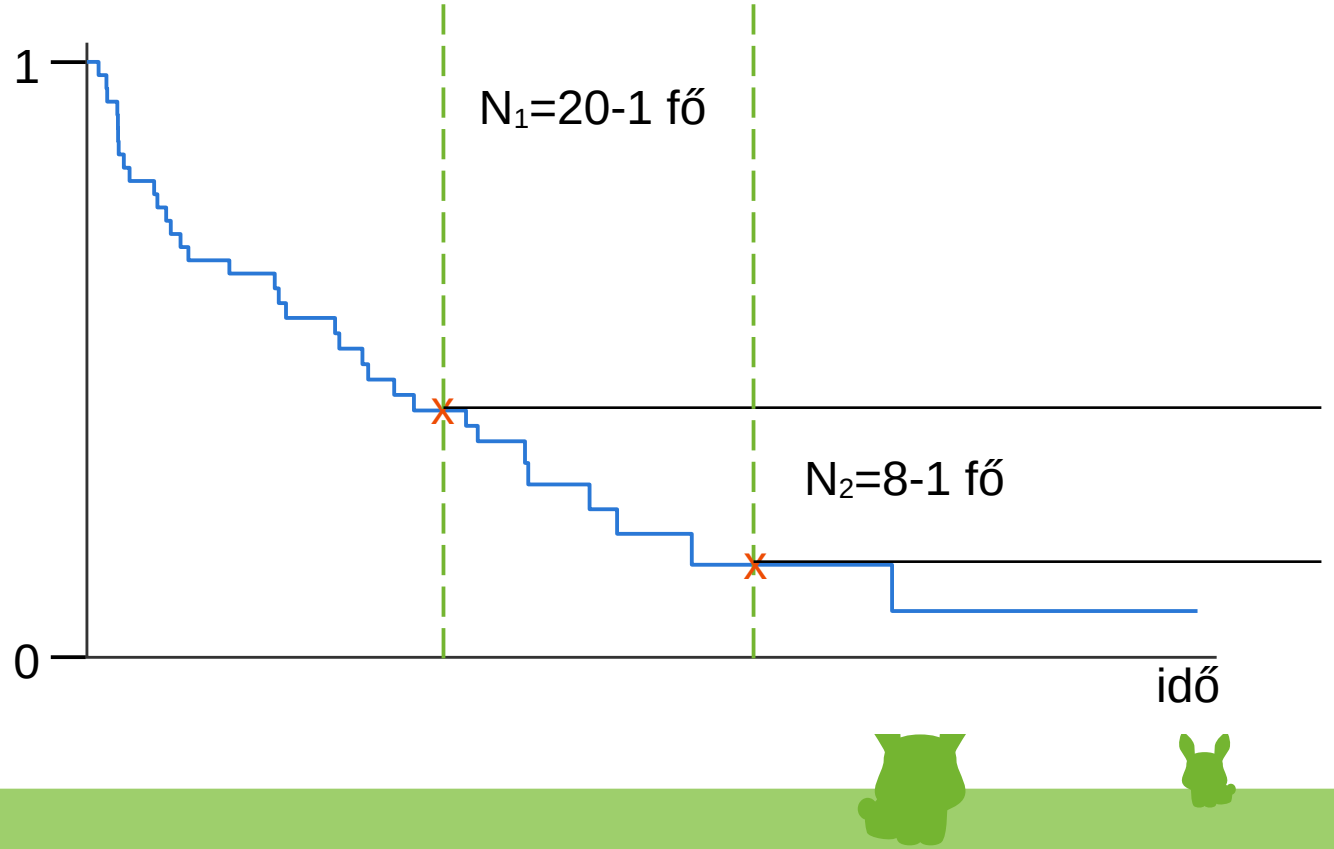
N_1=20-1 fő



Kaplan-Meier túlélési görbe

N=50 fő, túlélők száma
az idő függvényében

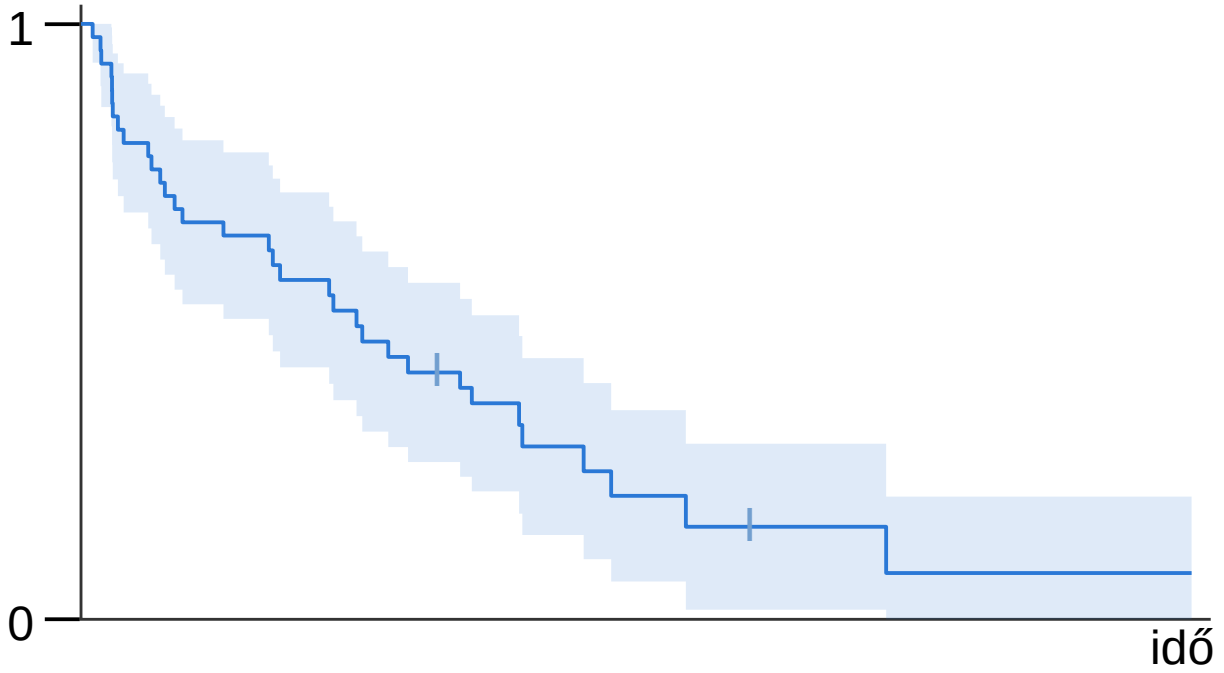
N_1=20-1 fő

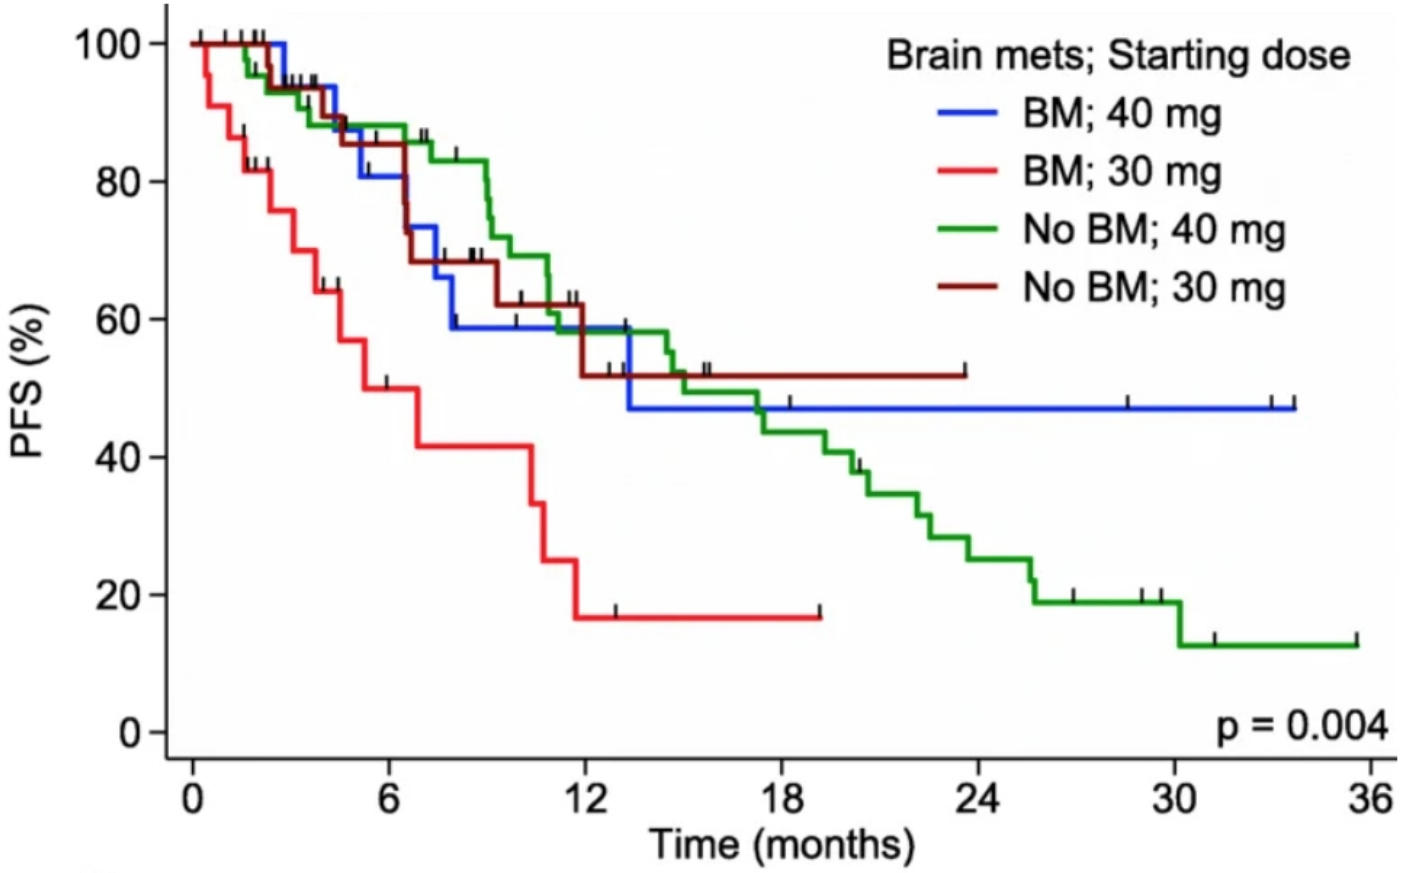


Kaplan-Meier túlélési görbe

N=50 fő, Kaplan-Meier túlélési görbe, 2 cenzorálttal

+ 95%-os konfidencia sáv





No. at risk							
BM; 40 mg	17	11	5	4	3	2	0
BM; 30 mg	23	6	2	1	0	0	0
No BM; 40 mg	44	36	21	15	8	3	0
No BM; 30 mg	35	20	5	1	0	0	0

3. gyakorlat: terd.csv elemzése

Két térdprotézis típus (A és B) retrospektív összehasonlítása.

2014. 01. 01-től vannak adataink, máig (2026. 10. 22).
Rajzoljuk meg a KM görbéket.

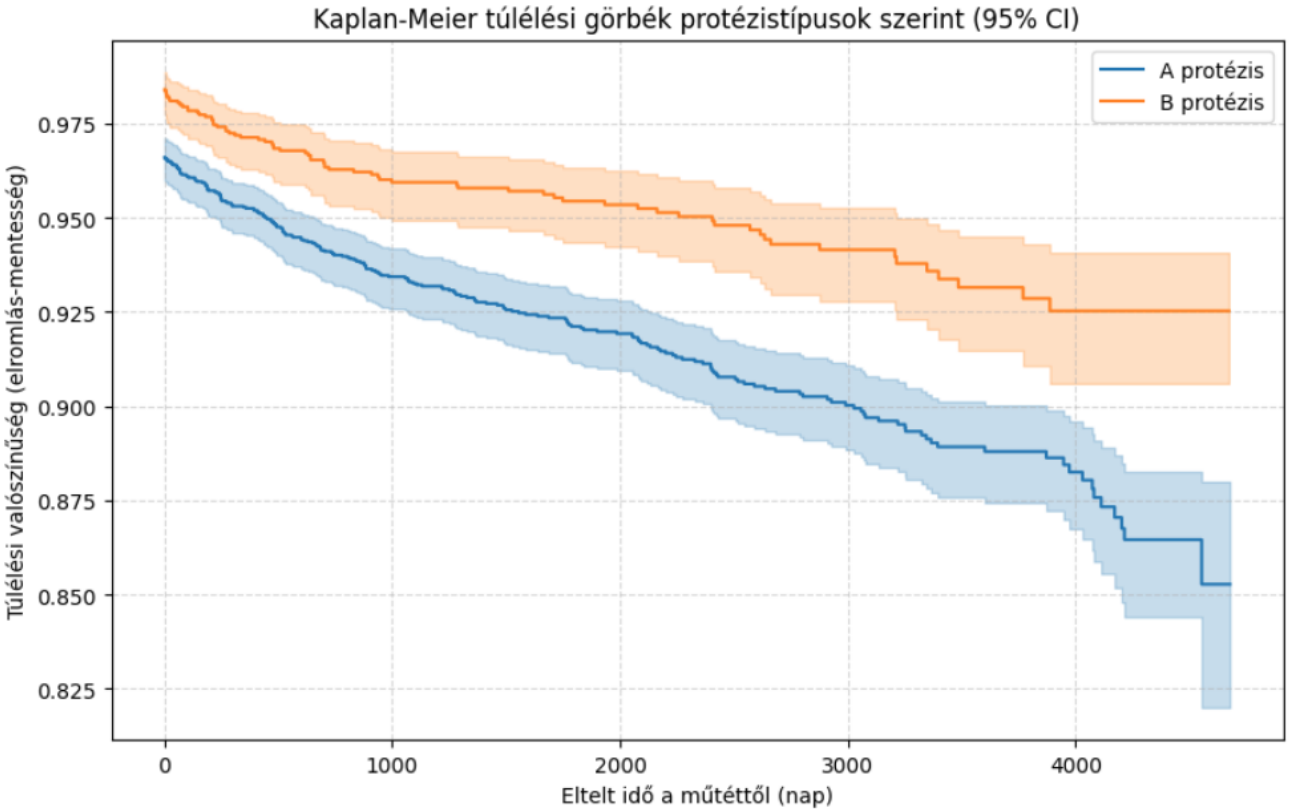
- https://colab.research.google.com/
- https://ruzsaz.github.io/terd.csv

Az első 10 sor:

	sorszam	mutet_datuma	protezis_tipus	elromlas_datuma	beteg_meghalt
0	1	2014-01-01	A	NaN	NaN
1	2	2014-01-02	A	NaN	NaN
2	3	2014-01-02	A	NaN	2022-10-15
3	4	2014-01-03	A	NaN	NaN
4	5	2014-01-03	A	NaN	NaN
5	6	2014-01-04	B	NaN	2022-08-26
6	7	2014-01-04	B	2015-12-03	NaN
7	8	2014-01-04	B	NaN	2016-04-09
8	9	2014-01-05	A	NaN	NaN
9	10	2014-01-05	B	NaN	NaN



Rajzolj két KM görbét, 95%-os konfidenciasávval. Az egyik a df.protezis_tipus=A, a másik =B lesz. A 0 pont a mutet_datuma, az index esemény az elromlas_datuma-kor következik be. Cenzorálás: a beteg_meghalt-kor, vagy ha üres, 2026-10-22 kor.



https://ruzsaz.github.io/stat1.pdf

HF1: Három közvélemény-kutató megmérte egy párt támogatottságát, az alábbi eredményekkel:

- 36.2%, 600 fős minta
- 29.8%, 2500 fős minta
- 31.4%, 1000 fős minta

Ezek hibahatáron belüli eltérések?

Az eredmények összesítésével milyen eredményt kapunk? Milyen hibahatárral?

HF2: „A magyarok fele olyan településen él, ahol a jövedelem nem éri el az országos átlagot”

A jövedelmek eloszlása nem szimmetrikus: jobbra elnyúló.

Generálj egy ilyen jövedelmeket szemléltető eloszlásból származó 10 milliós mintát, és nézd meg, hányan élnek az országos átlag alatt!

